ΒΑΣΕΙΣ ΔΕΔΟΜΕΝΩΝ

ΕΡΓΑΣΙΑ 2

Βήμα 1

Αφού κατεβάσαμε τα δεδομένα της άσκησης από τον εξωτερικό σύνδεσμο που υπάρχει στις οδηγίες προχωρήσαμε στην επιπεδοποίηση του αρχείου keywords.csv ως εξής:

Το αρχείο περιέχει δύο στήλες (πεδία), τις movie_id και keywords. Το movie_id είναι ένας ακέραιος αριθμός, ενώ το keywords περιέχει εμφωλευμένη λίστα από λέξεις κλειδιά και αναπαρίσταται σε μορφότυπο Json.

Σκοπός μας είναι να επιπεδοποιήσουμε το αρχείο keywords.csv, δηλαδή να το "σπάσουμε" σε δύο διαφορετικά αρχεία haskeyword.csv και keyword.csv. Το αρχείο haskeyword πρέπει να έχει δύο πεδία τα movie_id και keyword_id και θα απεικονίζει το movie_id κάθε ταινίας στο key_id μιας λέξης κλειδιού. Το αρχείο keyword.csv θα έχει δύο πεδία τα id και name και θα απεικονίζει κάθε id μιας λέξης κλειδί στην αντίστοιχη λέξη κλειδί.

Για το σκοπό αυτό γράψαμε πρόγραμμα σε python που διαβάζει το αρχείο keywords.csv και δημιουργεί τα αρχεία keyword.csv και haskeyword.csv. Το πρόγραμμα πρώτα διαβάζει το αρχείο keywords.csv, το οποίο περιέχει πληροφορίες για ταινίες και λέξεις κλειδιά που τις περιγράφουν. Κάθε γραμμή του αρχείου αναλύεται και το Json που περιέχει τις λέξεις κλειδιά αναλύεται χρησιμοποιώντας την literal_eval για να μετατραπεί σε λεξικό Python.

Γίνεται δημιουργία δύο δομών δεδομένων:

Ένα λεξικό keyword_dict όπου το κλειδί είναι το keyword_id και η τιμή του είναι το όνομα της λέξης κλειδιού.

Ένα λεξικό movie_keyword_map όπου το κλειδί είναι το movie_id και η τιμή του είναι ένα σύνολο από τα keyword_id που σχετίζονται με την ταινία.

Στη συνέχεια, τα δεδομένα αυτά χρησιμοποιούνται για να δημιουργηθούν τα δύο αρχεία CSV:

Το αρχείο keyword.csv περιέχει μια λίστα από τα μοναδικά keyword_id και τα ονόματα των λέξεων-κλειδιών.

Το αρχείο haskeyword.csv περιέχει τις αντιστοιχίσεις μεταξύ των movie_id και των keyword_id.

Το αρχείο κώδικα της python Που δημιουργήσαμε λέγεται **arraycreation.py**.

Βήμα 2

Αφού εγκαταστήσαμε το extension SQL Server Input στο Azure Data Studio, το χρησιμοποιήσαμε για να δημιουργήσουμε στην βάση μας τους πίνακες από τα αντίστοιχα csv αρχεία, συνολικά 12 πίνακες. Σε αρκετές περιπτώσεις χρειάστηκε να αναπροσαρμόσουμε κατάλληλα τους τύπους των πεδίων που είχε μαντέψει το SQL Server Input, σε πιο γενικούς.

Βήμα 3

Χρησιμοποιώντας την εντολή ALTER TABLE, δημιουργήσαμε περιορισμούς πρωτεύοντος και ξένου κλειδιού για τους πίνακες, **σύμφωνα με τις οδηγίες** της άσκησης.

Όλες αυτές οι εντολές υπάρχουν στο αρχείο **alter_tables.sql**.