Σχεδιασμός Βάσεων Δεδομένων
Διδάσκων: Ιωάννης Κωτίδης

Εαρινό εξάμηνο 2020-2021

Δεύτερη Σειρά Ασκήσεων

Ανάθεση: 10-05-2021
Παράδοση: 23-05-2021 Ώρα (23:55)

Οδηγίες

- *Η δεύτερη σειρά ασκήσεων είναι **ατομική** και **υποχρεωτική**.*
- *Η υποβολή της εργασίας πρέπει να γίνει στο eclass.*
- *Το παραδοτέο σας θα πρέπει να είναι ένα αρχείο PDF με όνομα AM.pdf (όπου AM είναι ο αριθμός μητρώου σας. π.χ. "3180001.pdf").*
- *Τα διαγράμματα πρέπει να είναι κατασκευασμένα σε κάποιο πρόγραμμα (της επιλογής σας) και όχι σκαναρισμένα χειρόγραφα.*
- *Πιθανή αντιγραφή θα τιμωρείται με μηδενισμό όλων των εμπλεκομένων.*
- *Για την επίλυση των ασκήσεων να μελετήσετε τις διαφάνειες των διαλέξεων του μαθήματος.*

Άσκηση 1 [Μονάδες 25]

Έστω η σχέση R(a,b,c) για την οποία ισχύουν τα εξής:

- Η σχέση R περιέχει 1.000.000 εγγραφές για την αποθήκευση των οποίων απαιτούνται 20.000 σελίδες.
- Δίνεται ότι V(R,a)=n, όπου n είναι θετικός ακέραιος αριθμός.
- Υπάρχει το ευρετήριο P στο γνώρισμα a της σχέσης R.
- Το ευρετήριο βρίσκεται στην μνήμη.

Θεωρείστε τα ακόλουθα επερωτήματα:

a. $\sigma_{a=2}(R)$
b. $\sigma_{K<=a<=L}(R)$, όπου K και L είναι σταθερές, έτσι ώστε n/10 τιμές να ανήκουν στο διάστημα [K...L].

Ζητείται:

1. Να υπολογίσετε το κόστος σε I/O των επερωτημάτων **a** και **b,** ως συνάρτηση του **n**, για κάθε μια από τις παρακάτω περιπτώσεις:
    i. Το ευρετήριο P είναι ευρετήριο συστάδων (clustered index)
    ii. Το ευρετήριο P είναι απλό ευρετήριο (nonclustered index)

2. Στην περίπτωση που το ευρετήριο P είναι απλό μπορούμε να εκτελέσουμε τα επερωτήματα a και b σαρώνοντας κάθε φορά την σχέση R (table scan), ή χρησιμοποιώντας το ευρετήριο αντίστοιχα. Για ποιές τιμές του **n** συμφέρει να χρησιμοποιήσουμε το ευρετήριο για να την εκτέλεση των επερωτημάτων a και b;

   Να απαντήσετε ξεχωριστά για κάθε επερώτημα.

Λύση Άσκησης 1

Από τα δεδομένα της άσκησης έχουμε:

T(R)=1.000.000 και B(R)=20.000 άρα σε μία σελίδα χωράνε T(R)/B(R)=1.000.000/20.000=50 εγγραφές της σχέσης R.
V(R,a)=n

Έστω X=$\sigma_{a=2}$(R) και Y=$\sigma_{K<=a<=L}$(R)

1.
Υπολογισμός κόστους του X

T(X)=1.000.000/n και B(X)=ceiling((1.000.000/n)/50) = ceiling(20.000/n)

i. Το ευρετήριο P είναι ευρετήριο συστάδων (clustered index)
cost(X)=B(X)=ceiling(20.000/n)

ii. Το ευρετήριο P είναι απλό ευρετήριο
cost(X)=T(X)=ceiling(1.000.000/n)

Υπολογισμός κόστους του Y

Με την υπόθεση ότι στο διάστημα [K..L] υπάρχουν n/10 τιμές έχουμε:

T(Y)=(1.000.000/n) * (n/10) = 100.000 και B(Y)=100.000/50 = 2.000

i. Το ευρετήριο P είναι ευρετήριο συστάδων (clustered index)
cost(Y)=B(Y)=2.000

ii. Το ευρετήριο P είναι απλό ευρετήριο
cost(Y)=T(Y)=100.000

2.

Στην περίπτωση του επερωτήματος $\sigma_{a=2}$(R), αν χρησιμοποιήσουμε το απλό ευρετήριο θα διαβάσουμε περίπου 1.000.000/n σελίδες. Αν διαβάσουμε όλη την σχέση θα διαβάσουμε 20000 σελίδες. Αρα για n> 50 μας συμφέρει να χρησιμοποιήσουμε το ευρετήριο.

Στην περίπτωση του επερωτήματος $\sigma_{K<=a<=L}$(R) αν χρησιμοποιήσουμε το απλό ευρετήριο πρέπει να διαβάσουμε 100.000 σελίδες. Σε αυτή την περίπτωση δεν μας συμφέρει η χρήση του ευρετηρίου.

Άσκηση 2 [Μονάδες 15]

Έστω οι σχέσεις R(a,b) και S(b,c) για τις οποίες υπάρχουν δύο ιστογράμματα. Ένα ιστόγραμμα για το γνώρισμα R.b και ένα ιστόγραμμα για το γνώρισμα S.b. Η μορφή των ιστογραμμάτων παρουσιάζεται στον παρακάτω πίνακα.

Διάστημα Τιμών	**R**	**S**
[1..20]	0	10
[21..40]	80	100
[41..60]	100	60
[61..80]	20	60
[81..100]	30	0

Κάθε γραμμή του πίνακα μας δίνει την πληροφορία ότι υπάρχουν T1 πλειάδες της σχέσης R και T2 πλειάδες της σχέσεις S, για τις οποίες οι τιμές των γνωρισμάτων R.b και S.b ανήκουν στο αντίστοιχο διάστημα. Για παράδειγμα η τρίτη γραμμή του πίνακα δηλώνει ότι υπάρχουν 100 πλειάδες της σχέσης R με τιμές στο γνώρισμα R.b που ανήκουν στο διάστημα [41..60], καθώς επίσης και 60 πλειάδες της σχέσης S με τιμές στο γνώρισμα S.b που ανήκουν στο ίδιο διάστημα.

Ζητείται να εκτιμήσετε το πλήθος των πλειάδων που θα εμφανίσει το παρακάτω επερώτημα:

```
SELECT a,c FROM R,S WHERE R.b=S.b
```

a. Βάσει των στατιστικών των ιστογραμμάτων R και S

b. Βάσει της υπόθεσης ότι όλες οι τιμές κατανέμονται ομοιόμορφα.

Λύση Άσκησης 2

Εκτίμηση βάσει των στατιστικών των ιστογραμμάτων R και S

Παρατηρούμε ότι και τα δύο ιστογράμματα είναι τύπου "Equi-Width" με τον ίδιο αριθμό bucket, τα οποία έχουν όλα το ίδιο εύρος τιμών (V=20). Βάσει αυτών, η εκτίμηση του πλήθους των πλειάδων της ισοσύνδεσης δύο αντιστοιχών bucket τα οποία περιλαμβάνουν T1 και T2 πλειάδες είναι (T1*T2)/V. Μπορούμε να εκτιμήσουμε το αποτέλεσμα της ισοσύνδεσης των σχέσεων R και S εξετάζοντας κάθε ζεύγος αντίστοιχων bucket και αθροίζοντας όπως φαίνεται στον πίνακα που ακολουθεί:

Διάστημα Τιμών	**R**	**S**	**(T1*T2)/V**
[1..20]	0	10	0
[21..40]	80	100	400
[41..60]	100	60	300
[61..80]	20	60	60
[81..100]	30	0	0
Αποτέλεσμα Ισοσύνδεσης			**760**

Εκτίμηση βάσει της υπόθεσης ότι οι τιμές ακολουθούν ομοιόμορφη κατανομή.

T(R)=T(S)=230 και V(R,b)=V(S,b)=100 οπότε έχουμε:

Αποτέλεσμα Ισοσύνδεσης = (T(R)*T(S))/100 = (230*230)/100=**529**

Άσκηση 3 [Μονάδες 30]

Έστω οι σχέσεις R (a,b,c) και S(c,d,e) για τις οποίες ισχύουν τα εξής:

1. Η σχέση R έχει 20.000 εγγραφές και σε μια σελίδα χωράνε 25 εγγραφές της σχέσης R.
2. Η σχέση S έχει 45.000 εγγραφές και σε μια σελίδα χωράνε 30 εγγραφές της σχέσης S.

Το μέγεθος της διαθέσιμης μνήμης είναι M=41 σελίδες.

Ζητείται:

1. Να εκτιμήσετε το κόστος σε I/O της σύζευξης **R⋈S** για κάθε έναν από τους παρακάτω αλγορίθμους:
    a. NLJ (Block Nested Loop Join)
    b. SMJ (Sort Merge Join)
    c. Hash Join

2. Συγκεκριμένα για τον αλγόριθμο SMJ ποιο είναι το ελάχιστο δυνατό κόστος (σε I/O) που μπορούμε να πετύχουμε για την υλοποίηση της σύζευξης **R⋈S**; Αναφέρετε δύο τρόπους για να πετύχουμε το ελάχιστο δυνατό κόστος.

Λύση Άσκησης 3

Από τα δεδομένα έχουμε:

B(R)=20.000/25=800, και B(S)=45.000/30=1500 και M=41

1.
a. NLJ

Το κόστος του αλγορίθμου είναι μικρότερο αν θέσουμε ως εξωτερική την μικρότερη σχέση:

cost(NLJ)=B(R)+ceil(B(R)/M-1)*B(S)=800+ceil(800/40)*1500=800+20*1500=**30.800 I/O**

b.SMJ

Επειδή B(R) + B(S) > M^2 (800+1500>41^2) δεν μπορούμε να εφαρμόσουμε την αποδοτική έκδοση του αλγορίθμου. Ισχύει ότι M^2>=max(B(R),B(S)) (41^2>1500) οπότε το κόστος υπολογίζεται ως εξής:

cost(SMJ)= 5 * (B(R)+B(S)) = 5 * (800+1500)= **11.500 I/O**

c.Hash Join

Χρησιμοποιούμε την μικρότερη σχέση R ως build relation και την S ως probe relation.

Επειδή B(R)< M^2 (800<41^2) δεν απαιτείται αναδρομική τμηματοποίηση οπότε και το κόστος είναι:

cost (HashJoin) = 3*(B(R)+B(S))=3*(800+1500)=**6900 I/O**

2.

Το ελάχιστο δυνατό κόστος που μπορούμε να πετύχουμε για την υλοποίηση της σύζευξης είναι να διαβάσουμε κάθε σχέση μία φορά δηλαδή να διαβάσουμε B(R) + B(S) σελίδες.

Στην περίπτωση του αλγορίθμου SMJ το ελάχιστο δυνατό κόστος μπορούμε να το πετύχουμε αν αυξήσουμε την διαθέσιμη μνήμη σε 800 σελίδες ώστε να χωράει την μικρότερη σχέση (R). Διαβάζουμε την σχέση και την ταξινομούμε στην μνήμη όπου και την κρατάμε. Στην συνέχεια διαβάζουμε μία κάθε φορά σελίδα της σχέσης S, την ταξινομούμε και ψάχνουμε για κοινές εγγραφές με την R. Οπότε συνολικά χρειαζόμαστε 801 σελίδες μνήμης (M=801).

Ένας άλλος τρόπος να πετύχουμε το ελάχιστο δυνατό κόστος με τον αλγόριθμο SMJ είναι και οι δύο σχέσεις να είναι ταξινομημένες ως προς το γνώρισμα που γίνεται η σύζευξη. Για παράδειγμα να υπάρχουν ευρετήρια συστάδων στα γνωρίσματα R.c και S.c.

Άσκηση 4 [μονάδες 30]

Έστω οι παρακάτω σχέσεις της βιβλιογραφικής βάσης δεδομένων της Βιβλιοθήκης ενός Κέντρου Νεότητας.

ΔΑΝΕΙΖΟΜΕΝΟΙ(**ΚΔ,** Επώνυμο, Όνομα, Ηλικία, Φύλο, Ιδιότητα)
ΒΙΒΛΙΑ(**ΚΒ,** Τίτλος, Εκδότης, Έκδοση, Σελίδες, Σημειώσεις)
ΔΑΝΕΙΣΜΟΙ(**ΚΔ,ΚΒ,** Ημερομηνία_Δανεισμού)

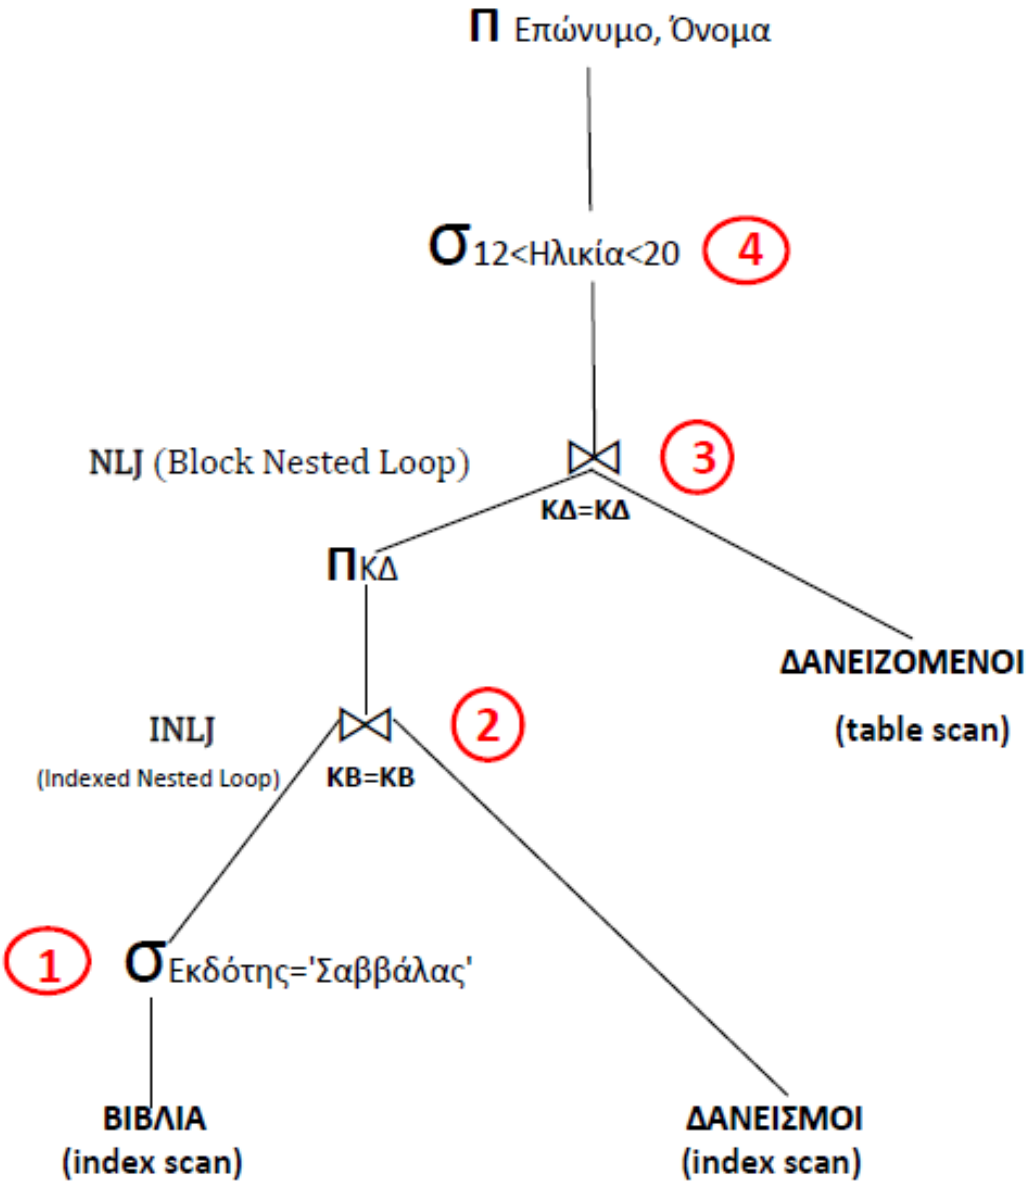
Θεωρείστε ότι:

1. Υπάρχουν 10.000 εγγραφές δανειζόμενων αποθηκευμένες σε 1.000 σελίδες.
2. Υπάρχουν 50.000 εγγραφές βιβλίων αποθηκευμένες σε 5.000 σελίδες
3. Υπάρχουν 300.000 εγγραφές δανεισμών αποθηκευμένες σε 15.000 σελίδες
4. Υπάρχουν 500 διαφορετικοί εκδότες
5. Οι ηλικίες των δανειζομένων κυμαίνονται από 7 έως και 24 έτη.
6. Το μέγεθος της διαθέσιμης μνήμης είναι 20 σελίδες (**M=20**).
7. Υπάρχει ένα απλό ευρετήριο (non clustered) στο γνώρισμα **Εκδότης** της σχέσης ΒΙΒΛΙΑ.
8. Υπάρχει ένα ευρετήριο συστάδων (clustered index) στο γνώρισμα **ΚΒ** της σχέσης ΔΑΝΕΙΣΜΟΙ.
9. Τα παραπάνω δύο ευρετήρια είναι τα **μόνα** που υπάρχουν. Μην θεωρήσετε ότι για κάθε πρωτεύον κλειδί των σχέσεων υπάρχει ευρετήριο συστάδων.
10. Τα ευρετήρια βρίσκονται στην μνήμη.
11. Όπου απαιτείται υποθέστε ότι τα δεδομένα κατανέμονται ομοιόμορφα.
12. Οι επιλογές είναι μεταξύ τους ανεξάρτητες.

Δίνεται το ακόλουθο SQL επερώτημα:

```
SELECT Επώνυμο, Όνομα
   FROM ΔΑΝΕΙΖΟΜΕΝΟΙ, ΒΙΒΛΙΑ, ΔΑΝΕΙΣΜΟΊ
WHERE ΔΑΝΕΙΖΌΜΕΝΟΙ.ΚΔ=ΔΑΝΕΙΣΜΟΙ.ΚΔ AND
          ΔΑΝΕΙΣΜΟΙ.ΚΒ=ΒΙΒΛΙΑ.ΚΒ AND
          Εκδότης='Σαββάλας' AND   ( Ηλικία > 12 AND Ηλικία < 20)
```

Ζητείται να υπολογίσετε το κόστος σε I/O του φυσικού πλάνου εκτέλεσης που ακολουθεί. Συγκεκριμένα να υπολογίσετε το κόστος σε I/O (εφόσον υφίσταται) για κάθε μία από τις 4 αριθμημένες επιμέρους λειτουργίες του πλάνου και να δείξετε πως αυτό προκύπτει. Επιπλέον για κάθε μια από τις 4 λειτουργίες να προσδιορίσετε τον αριθμό των εγγραφών που προκύπτουν στην έξοδο και να δείξετε πως αυτός υπολογίζεται.



Λύση Άσκησης 4

Από τα δεδομένα της άσκησης έχουμε:

T(ΔΑΝΕΙΖΟΜΕΝΟΙ)=10.000
B(ΔΑΝΕΙΖΟΜΕΝΟΙ)=1.000
T(ΒΙΒΛΙΑ)=50.000
B(ΒΙΒΛΙΑ)=5.000
T(ΔΑΝΕΙΣΜΟΙ)=300.000
B(ΔΑΝΕΙΣΜΟΙ=15.000
V(ΒΙΒΛΙΑ, Εκδότης)=500
V(ΔΑΝΕΙΣΜΟΙ,Ηλικία)=18

Από τα παραπάνω προκύπτουν τα εξής:

Μία σελίδα χωράει 10 εγγραφές της σχέσης ΔΑΝΕΙΖΟΜΕΝΟΙ (10.000/1000=10)
Μία σελίδα χωράει 10 εγγραφές της σχέσης ΒΙΒΛΙΑ (50.000/5.000=10)
Μία σελίδα χωράει 20 εγγραφές της σχέσης ΔΑΝΕΙΣΜΟΙ (300.000/15.000=20)

Βήμα 1: Κόστος=100 I/O, Αριθμός εγγραφών στην έξοδο=100.

T($\sigma_{\text{Εκδότης='Σαββάλας'}}$**)**= T(B)*1/500 = 50000/500 = **100 εγγραφές.**

cost($\sigma_{\text{Εκδότης='Σαββάλας'}}$**)=100 I/0** **(**Απλό Ευρετήριο**)**

Σημείωση 1: Οι 100 εγγραφές που προκύπτουν στην έξοδο χωράνε στην μνήμη διότι **M=20** και κάθε σελίδα χωράει **10** εγγραφές της σχέσης ΒΙΒΛΙΑ.

Βήμα 2: Κόστος=100 I/O, Αριθμός εγγραφών στην έξοδο=600.

Για κάθε μία από τις 100 εγγραφές που δέχεται ως είσοδο ο αλγόριθμος INLJ χρησιμοποιεί το ευρετήριο που υπάρχει στο γνώρισμα **ΔΑΝΕΙΣΜΟΙ.ΚΒ** (lookup/probe) για να ανακτήσει τις αντίστοιχες εγγραφές της σχέσης ΔΑΝΕΙΣΜΟΙ.

Σημείωση 2: Οι τιμές του γνωρίσματος **ΚΒ** υπάρχουν στην μνήμη διότι βρίσκονται στα φύλλα του ευρετηρίου **ΔΑΝΕΙΣΜΟΙ.ΚΒ.** Επειδή όμως χρειάζονται οι τιμές του γνωρίσματος **ΚΔ** πρέπει να ανακτηθούν οι αντίστοιχες εγγραφές.

Επειδή υποθέτουμε ομοιόμορφη κατανομή των τιμών για κάθε εγγραφή που δέχεται ως είσοδο ο INLJ θα επιστρέψει **6** εγγραφές δανεισμών:

T(ΔΑΝΕΙΣΜΟΙ)/V(ΔΑΝΕΙΣΜΟΙ, ΚΒ) = 300000/50000=6.

Το ευρετήριο στο γνώρισμα **ΔΑΝΕΙΣΜΟΙ.ΚΒ** είναι ευρετήριο συστάδων, και δεδομένου ότι 6 εγγραφές δανεισμών χωράνε σε μία σελίδα, το κόστος είναι **100 I/O.**

Ο αριθμός των εγγραφών στην έξοδο είναι 6*100=**600**.

Βήμα 3: Κόστος=1000 I/O, Αριθμός εγγραφών στην έξοδο=600.

Μία σελίδα χωράει 20 εγγραφές της σχέσης ΔΑΝΕΙΣΜΟΙ ή 10 εγγραφές της σχέσης ΒΙΒΛΙΑ. Δεδομένου ότι M=20 χωράνε στην μνήμη 400 εγγραφές δανεισμών ή 200 εγγραφές βιβλίων. Επειδή στην έξοδο της ισοσύνδεσης των σχέσεων ΒΙΒΛΙΑ ΚΑΙ ΔΑΝΕΙΣΜΟΙ προβάλουμε το γνώρισμα **ΚΔ,** μπορούμε εκ του ασφαλούς να υποθέσουμε ότι και οι 600 κωδικοί δανειζομένων χωράνε στην μνήμη. Βάσει αυτής της υπόθεσης για να υλοποιηθεί η συγκεκριμένη ισοσύνδεση αρκεί να διαβάσουμε την σχέση ΔΑΝΕΙΖΟΜΕΝΟΙ. Το κόστος είναι **1000 I/O** διότι Β(ΔΑΝΕΙΖΟΜΕΝΟΙ)=1000. Στην έξοδο του JOIN θα έχουμε **600** εγγραφές.

Βήμα 4: Κόστος=0 I/O, Αριθμός εγγραφών στην έξοδο=234.

Η λειτουργία της επιλογής σε αυτό το σημείο μπορεί να εκτελεστεί στην μνήμη. Οι εγγραφές στην έξοδο υπολογίζονται ως εξής:

- Αριθμός εγγραφών στην είσοδο της επιλογής=600
- V(ΔΑΝΕΙΖΟΜΕΝΟΙ, Ηλικία)=18
- Τιμές στο διάστημα (12..20)=7

οπότε έχουμε 600* 7/18=4200/18=233,333 δηλαδή **234 εγγραφές.**

Άσκηση 5 [BONUS Μονάδες 15]

Δίνεται το παρακάτω λογικό σχήμα:

R1(a,b), R2(b,c), R3(b,e), R4(b,f)

Ζητείται:

1. Να γράψετε ένα λογικό πλάνο αριστερού βάθους (left-deep) για το ακόλουθο SQL ερώτημα. Μπορείτε να σχεδιάσετε το πλάνο ή να το γράψετε σε σχεσιακή άλγεβρα.

   ```
   Select *
     from R1, R2,R3,R4
   where R1.b=R2.b and R2.b=R3.b and R3.b=R4.b
   ```

2. Δεδομένου ότι υπάρχουν μόνο τέσσερα ευρετήρια, ένα ευρετήριο συστάδων (clustered index) στο γνώρισμα b κάθε σχέσης, και ότι καμία σχέση ή ενδιάμεσο αποτέλεσμα δεν χωράει στην μνήμη, να προτείνετε ένα αποδοτικό φυσικό πλάνο για το λογικό πλάνο που σχεδιάσατε στο ερώτημα ένα (1). Με άλλα λόγια να προσδιορίσετε τον αλγόριθμο ισοσύνδεσης (hash join, nested loop, sortmerge κ.λπ.) καθώς και την μέθοδο πρόσβασης για το διάβασμα των σχέσεων (table scan, index scan κ.λπ.). Να εξηγήσετε γιατί το πλάνο που προτείνετε είναι αποδοτικό.

3. Να εκτιμήσετε το κόστος σε I/O του φυσικού πλάνου που προτείνατε στο ερώτημα δύο (2). Η εκτίμηση του κόστους να γίνει σε όρους Β(Χ). Οπου Β(Χ)=αριθμός σελίδων της σχέσης Χ. Να αιτιολογήσετε την απάντησή σας.

Λύση Άσκησης 5

1. ((R1⋈ b=b R2) ⋈ b=b R3) ⋈ b=b R4)

2. Table scan (και το clustered index scan μπορεί να θεωρηθεί σωστό) για το διάβασμα των σχέσεων και SMJ για την υλοποίηση των ισοσυνδέσεων διότι όλες οι σχέσεις είναι ταξινομημένες ως προς το γνώρισμα b.

3. B(R1) + B(R2) + B(R3) + B(R4)