Σχεδιασμός Βάσεων Δεδομένων
Διδάσκων: Ιωάννης Κωτίδης

Εαρινό εξάμηνο 2020-2021

Πρώτη Εργασία

"Βάση Δεδομένων Κινηματογραφικών Ταινιών"

Ζήτημα Πρώτο

1.

```
select title from movies where pyear between 1990 and 2000

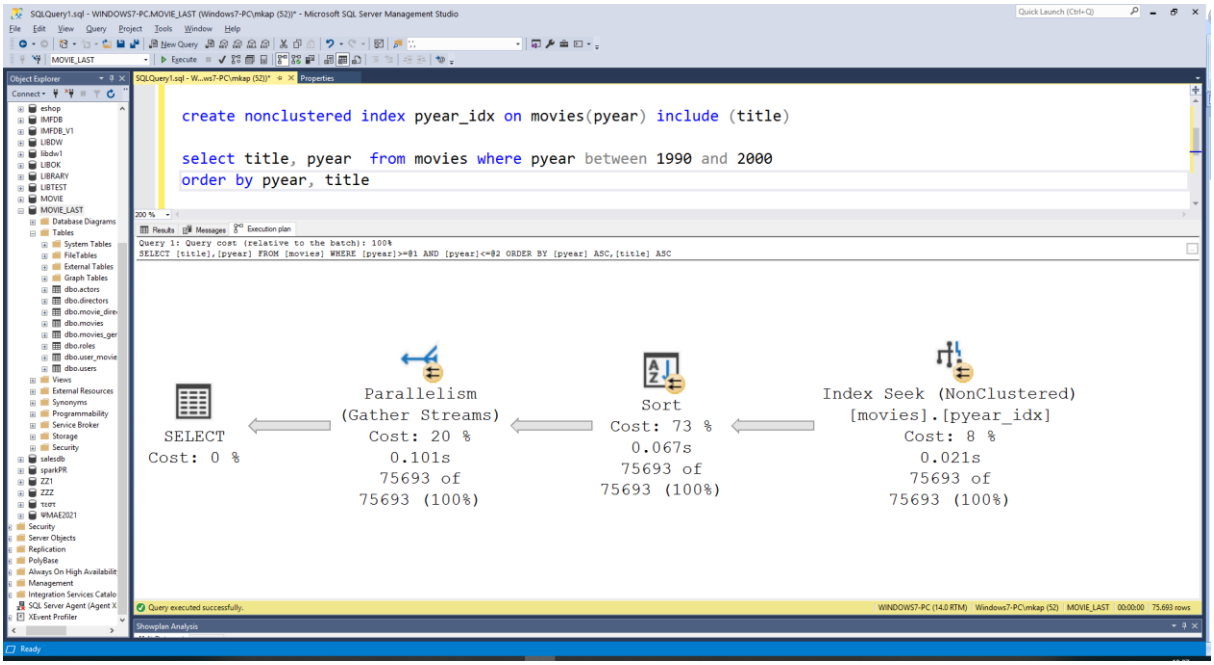
select pyear, title from movies where pyear between 1990 and 2000

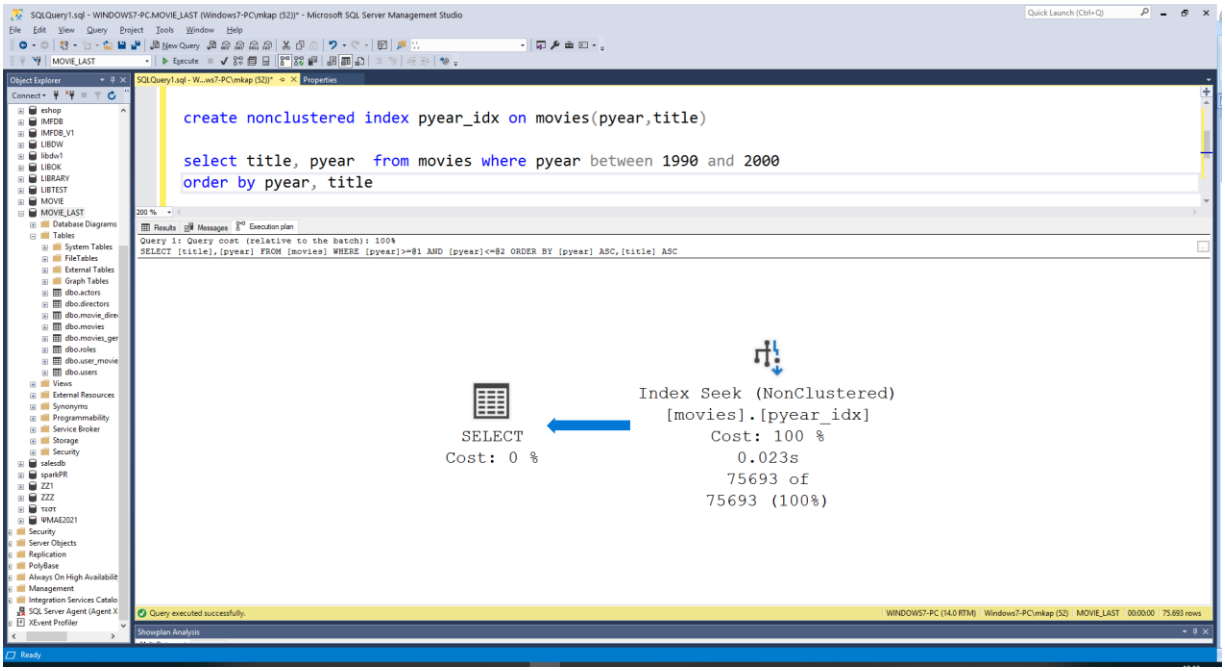
select title, pyear  from movies where pyear between 1990 and 2000
order by pyear, title
```

Δημιουργία ευρετηρίων

```
create index pyear_idx on movies(pyear) include (title) ή
create index pyear_idx on movies(pyear,title)
```

Τα παραπάνω δύο ευρετήρια επιταχύνουν την εκτέλεση και των τριών ερωτημάτων. Ωστόσο για το τρίτο ερώτημα καταλληλότερο είναι το δεύτερο ευρετήριο διότι περιέχει τους τίτλους ταξινομημένους. Παρατηρούμε ότι στο δεύτερο πλάνο δεν υπάρχει η λειτουργία της ταξινόμησης



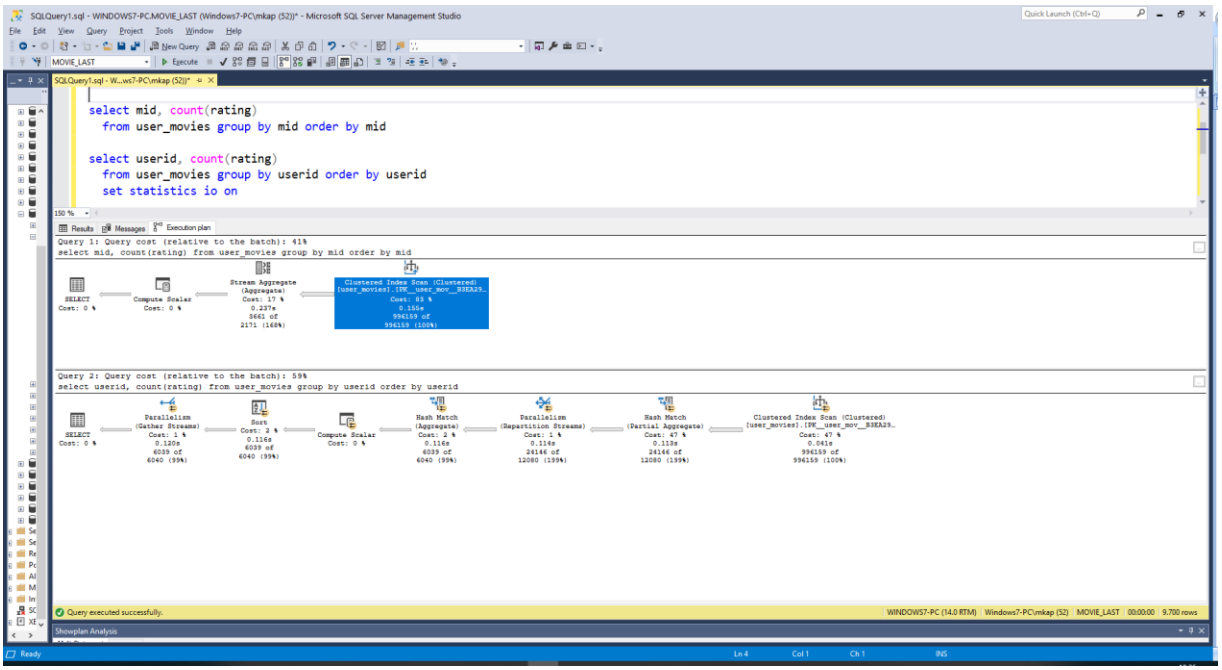


2.

```
select mid, count(rating)
  from user_movies group by mid order by mid

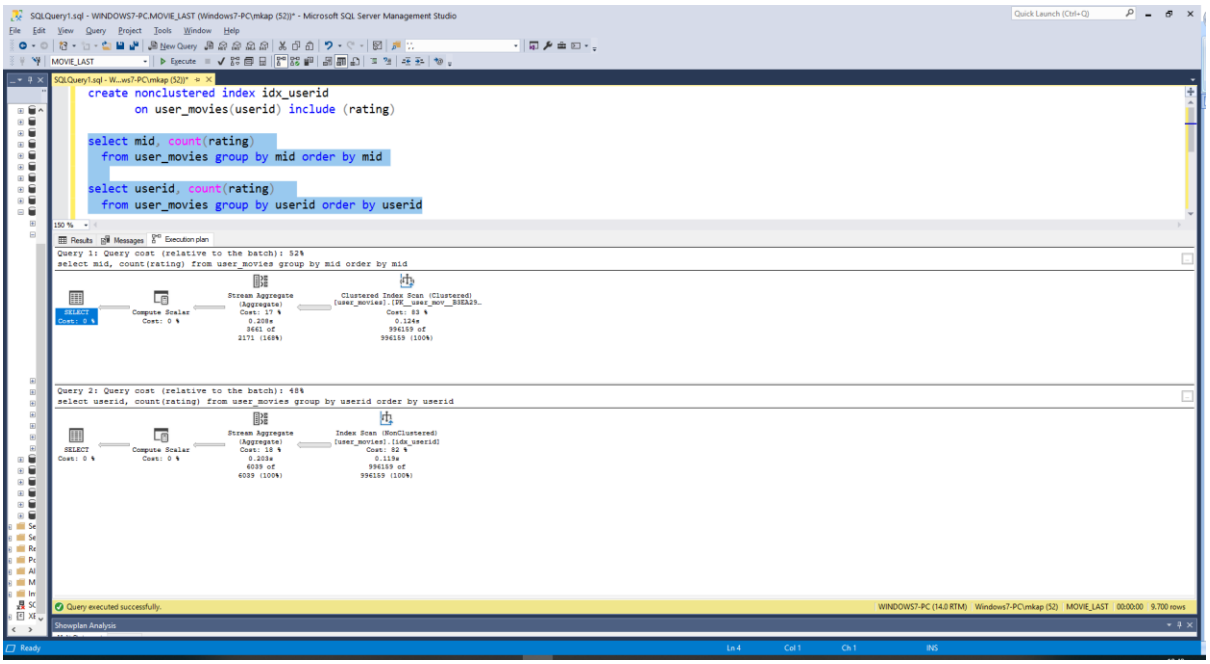
select userid, count(rating)
  from user_movies group by userid order by userid
```

Οι εγγραφές είναι διατεταγμένες με βάση τον κωδικό της ταινίας εξαιτίας του πρωτεύοντος κλειδιού του πίνακα **(primary key (mid, userid))** γεγονός που επιταχύνει την εκτέλεση του πρώτου ερωτήματος. Εκτελούμε τα δύο ερωτήματα σε δέσμη και βλέπουμε ότι το δεύτερο ερώτημα έχει το μεγαλύτερο κόστος.



Επιλέγουμε να δημιουργήσουμε το παρακάτω ευρετήριο για να βελτιώσουμε το δεύτερο ερώτημα.

```
create nonclustered index idx_userid
       on user_movies(userid) include (rating)
```



Ζήτημα Δεύτερο

1.

```
select  title
  from movies, movies_genre
 where movies.mid=movies_genre.mid and genre='Adventure'

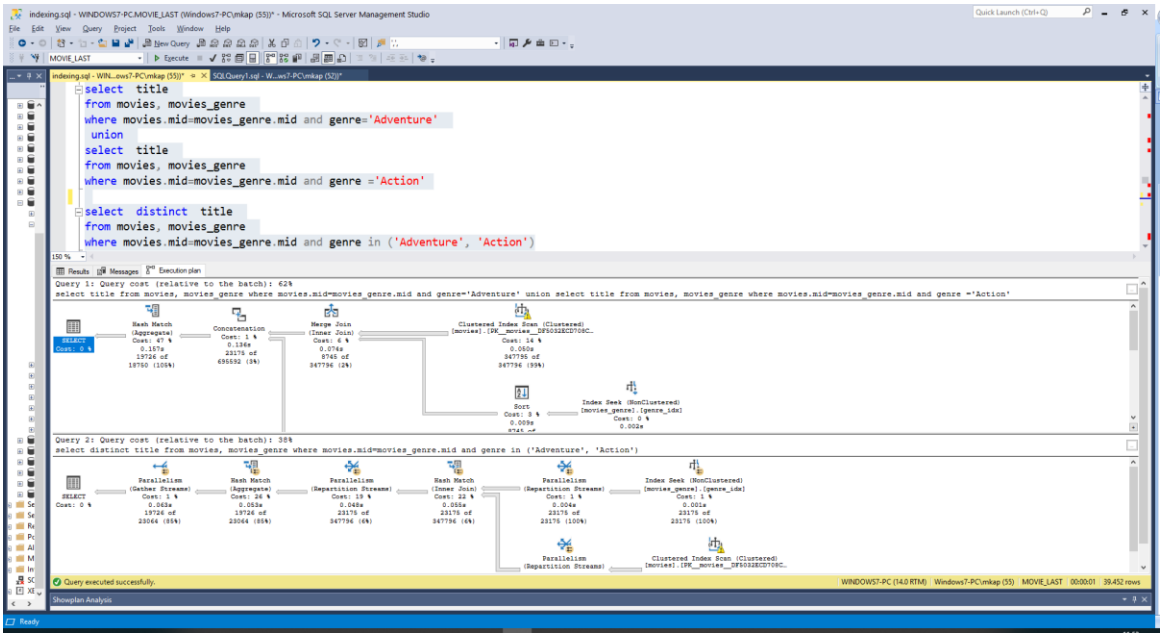
   UNION

  select  title
   from movies, movies_genre
  where movies.mid=movies_genre.mid and genre ='Action'
```

Το παρακάτω ερώτημα έχει τα ίδια αποτελέσματα αλλά είναι αποδοτικότερο.

```
select  distinct  title
from movies, movies_genre
where movies.mid=movies_genre.mid and
                genre in ('Adventure', 'Action')
```

Αν εκτελέσουμε και τα δύο ερωτήματα σε δέσμη θα δούμε ότι το κόστος της εκτέλεσης του δευτέρου ερωτήματος ανέρχεται στο 38% του συνολικού κόστους.



Το ακόλουθο ευρετήριο επιταχύνει την εκτέλεση του δεύτερου ερωτήματος:

```
create nonclustered index genre_idx
        on movies_genre(genre) include (mid)
```

Σημείωση: Από το παραπάνω παράδειγμα είναι λάθος να οδηγηθούμε σε συμπεράσματα του τύπου ότι ο τελεστής IN (ή OR) είναι αποδοτικότερος από το UNION. Στην συγκεκριμένη περίπτωση η διαφορά αποδίδεται στο γεγονός ότι εκτελείτε ο τελεστής OR στο ίδιο πεδίο.

Στο παρακάτω παράδειγμα που εφαρμόζουμε τον τελεστή OR σε διαφορετικά πεδία τα ερωτήματα είναι σχεδόν ισοδύναμα (UNION=48%, OR=52% του συνολικού κόστους). Σε περιπτώσεις λογικής διάζευξης διαφορετικών πεδίων για τα οποία υπάρχουν διαφορετικά ευρετήρια, ο SQL SERVER ενδέχεται να μην μπορεί να αξιοποιήσει κάποιο από αυτά (ή και όλα).

```
select title from movies where pyear between 1995 and 2000
union
select title from movies where mrank > 9.5

select distinct title from movies
  where (pyear between 1995 and 2000 OR mrank > 9.5)
```

2. "Εμφάνισε τους κωδικούς και τους τίτλους των ταινιών στις οποίες συμμετέχουν μόνο άντρες ηθοποιοί".

Τα παρακάτω τρία επερωτήματα σε SQL απαντούν στο παραπάνω ερώτημα:

```
select   movies.mid, title
  from movies
  where  ( exists
             (select 1 from roles, actors
                where movies.mid=roles.mid and roles.aid=actors.aid and
               gender='M') and
          not exists
              (select 1 from roles, actors
               where movies.mid=roles.mid and roles.aid=actors.aid and
              gender='F') )


select   movies.mid, title
   from movies,roles,actors
    where movies.mid=roles.mid and
            roles.aid=actors.aid
except

 select   movies.mid, title
   from movies,roles,actors
    where movies.mid=roles.mid and
            roles.aid=actors.aid and gender= 'F'
```

```
select   distinct movies.mid, title
   from movies,roles,actors
    where movies.mid=roles.mid and
         roles.aid=actors.aid and movies.mid not in
               (select   movies.mid
                 from movies,roles,actors
                  where movies.mid=roles.mid and
                          roles.aid=actors.aid and gender= 'F')
```

Αν εκτελέσουμε τα παραπάνω επερωτήματα σε δέσμη διαπιστώνουμε ότι το κόστος εκτέλεσης ανέρχεται αντίστοιχα σε 34%, σε 29% και 37% του συνολικού κόστους.

Με την δημιουργία των παρακάτω ευρετηρίων το κόστος εκτέλεσης ανέρχεται αντίστοιχα σε 29% για το πρώτο και το δεύτερο επερωτάμε και σε 42% για το τρίτο.

```
create index idx_aid on  roles(aid)
create index idx_gender on actors(gender)
```