Συστήματα Διαχείρισης και Ανάλυσης Δεδομένων
Διδάσκων: Ιωάννης Κωτίδης

Εαρινό εξάμηνο 2021-2022

Λύση Άσκησης 1

1. **Αριθμός εγγραφών που χωρούν σε ένα μπλοκ.**

   Χωρητικότητα Μπλοκ= floor(Μέγεθος Μπλοκ/Μέγεθος Εγγραφής) = floor(2048 bytes / 100 bytes) = **floor(20,48)=20 εγγραφές.**

2. **Συνολικός αριθμός απαιτούμενων μπλοκ για την αποθήκευση του αρχείου.**

   Συνολικός Αριθμός Μπλοκ = Αριθμός Εγγραφών / Χωρητικότητα Μπλοκ = 120000/20=**6000 μπλοκ.**

3. **Αριθμός κυλίνδρων που καταλαμβάνει το αρχείο αν τα μπλοκ του αποθηκεύονται συνεχόμενα στον δίσκο.**

   Ένα ίχνος (track) διαθέτει 100 τομείς των 1024 bytes. Κάθε μπλοκ είναι 2048 bytes δηλαδή αποθηκεύεται σε δύο τομείς, οπότε σε ένα ίχνος χωράνε 50 μπλοκ. Ένας κύλινδρος έχει 20 ίχνη (10 επιφάνειες * 2 ίχνη) = 20 ίχνη *50 μπλοκ = 1000 μπλοκ. Οπότε για την αποθήκευση του αρχείου απαιτούνται 6000/1000 = **6 κύλινδροι.**

4. **Συνολικός αριθμός εγγραφών που χωράνε στον δίσκο.**

   Συνολικός Αριθμός Εγγραφών = Συνολικός Αριθμός Μπλοκ Δίσκου * Χωρητικότητα Μπλοκ

   Συνολικός Αριθμός Μπλοκ Δίσκου = Μπλοκ ανά Ίχνος * Ιχνη * Επιφάνειες = 50*1000*20=**1.000.000 μπλοκ**.

   Συνολικός Αριθμός Εγγραφών = 1.000.000*20=**20.000.000 εγγραφές.**

5. **Απαιτούμενος χρόνος για την ανάγνωση ολόκληρου του αρχείου**

   Συνολικός Χρόνος για το Διάβασμα του Αρχείου = Μέσος Χρόνος Μετακίνησης Κεφαλής + Μέση Καθυστέρηση Περιστροφής + Χρόνος Ανάγνωσης των Μπλοκ του Αρχείου.

   Μέσος Χρόνος Μετακίνησης Κεφαλής = 0,008 sec (από την εκφώνηση της άσκησης).

   Μέση Καθυστέρηση Περιστροφής = (60 sec / 7200 rpm) / 2 =0,00415 sec

   Χρόνος Ανάγνωσης των Μπλοκ του Αρχείου.
   Το αρχείο καταλαμβάνει 6 κυλίνδρους (από ερώτημα 3). Για το διάβασμα ενός ίχνους χρειάζονται 60 sec / 7200(rpm)=0,0083 sec. Για το διάβασμα ενός κυλίνδρου απαιτούνται 0,0083*20 =0,166 sec. Για το διάβασμα των 6 κυλίνδρων απαιτούνται **6*0,166=0,996 sec.**

   Συνολικός Χρόνος για το Διάβασμα του Αρχείου = 0,008 sec + 0,00415 + 0,996 sec = 1,00815 sec

6. **Απαιτούμενος χρόνος για την ανάγνωση 10000 τυχαίων εγγραφών του αρχείου.**

   Χρόνος Ανάγνωσης Ενός Μπλοκ = Μέσος Χρόνος Μετακίνησης Κεφαλής + Μέση Καθυστέρησης Περιστροφής + Χρόνος Μεταφοράς του Μπλοκ.

Σε 0,0083 sec διαβάζουμε ένα ίχνος το οποίο περιέχει 50 μπλοκ ,δηλαδή διαβάζουμε ένα μπλοκ σε 0,0083/50=0,000166 sec.

Ο χρόνος ανάγνωσης 10000 μπλοκ υπολογίζεται ως εξής: (0,008+0,00415+0,000166)*10000 = **123,16 sec.**

Λύση Άσκησης 2

α) Για την αποθήκευση των 6000 εγγραφών απαιτούνται 6000/10=600 μπλοκ.
Για την αποθήκευση των κάδων απαιτούνται 6000/200= 30 μπλοκ.
Για την αποθήκευση των ζευγών κλειδιού-δείκτη απαιτούνται (6000/15)/50=8 μπλοκ.
Σύνολο 600+30+8 = 638 μπλοκ.

β) Για την αποθήκευση των εγγραφών και των κάδων δεν αλλάζει κάτι σε σχέση με το ερώτημα α. Δηλαδή χρειαζόμαστε **600+30=630 σελίδες.**

Για την αποθήκευση των ζευγών κλειδιού-δείκτη απαιτούνται: ((6000/50)=**120** μπλοκ στην περίπτωση που όλα τα κλειδιά είναι διαφορετικά και μόνο **1** μπλοκ στην περίπτωση που όλα τα κλειδιά είναι ίδια.

Μέγιστος αριθμός απαιτούμενων μπλοκ = 600+30+120=750 μπλοκ.
Ελάχιστος αριθμός απαιτούμενων μπλοκ = 600+30+1=631 μπλοκ.

γ) Στην καλύτερη περίπτωση:

- θα χρειαστεί να διαβάσουμε μόνο ένα μπλοκ του ευρετηρίου ώστε να εντοπίσουμε το ζεύγος κλειδιού-δείκτη που αναζητούμε.
- Οι 15 εγγραφές που θέλουμε να ανακτήσουμε μπορεί να είναι ομαδοποιημένες σε συνεχόμενα μπλοκ.

Ελάχιστος Αριθμός Μπλοκ = 1 (μπλοκ ευρετηρίου) + 1 (μπλοκ που περιέχει τον κάδο) + ceiling [15/10] (μπλοκ με τις εγγραφές) = **4.**

Στην χειρότερη περίπτωση:

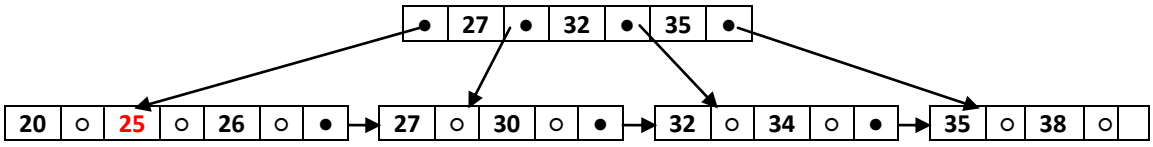
- θα χρειαστεί να διαβάσουμε όλο το ευρετήριο.
- Οι δεκαπέντε εγγραφές θα βρίσκονται σε 15 διαφορετικά μπλοκ.

Μέγιστος Αριθμός Μπλοκ = 8 (μπλοκ ευρετηρίου) + 1 (μπλοκ που περιέχει τον κάδο) +15 (μπλοκ με τις εγγραφές) = **24.**

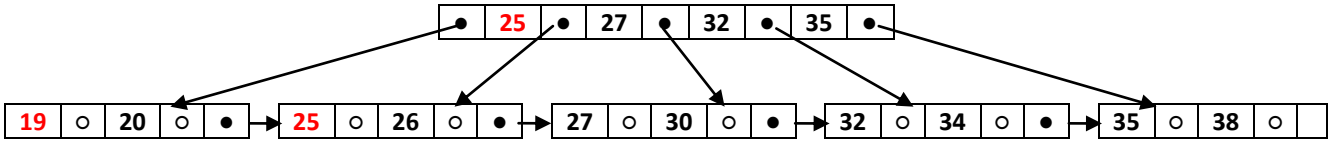
Μέσος Αριθμός Μπλοκ = (4 +24) /2 =14.

Λύση Άσκησης 3

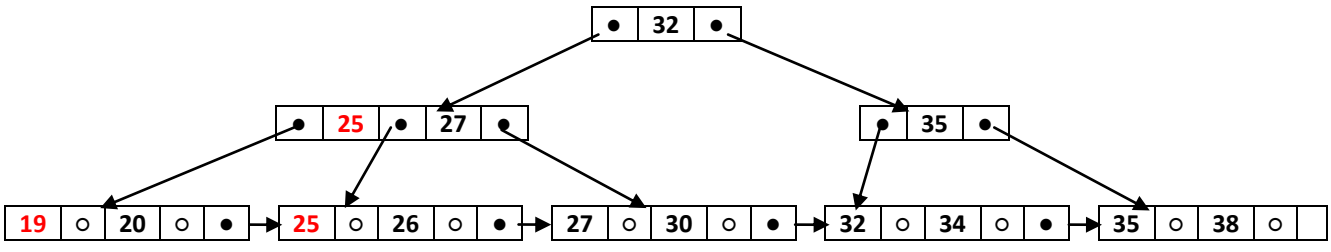
Εισαγωγή τιμής "25" : Η τιμή **25** τοποθετείται αριστερά στον πρώτο κόμβο-φύλλο διότι είναι μικρότερη του **27**. Εφόσον **n=3** και ο κόμβος-φύλλο περιέχει δύο τιμές χωράει και η τιμή **25**. Θα τοποθετηθεί ανάμεσα στις τιμές **20** και **26 (20<25<26).**



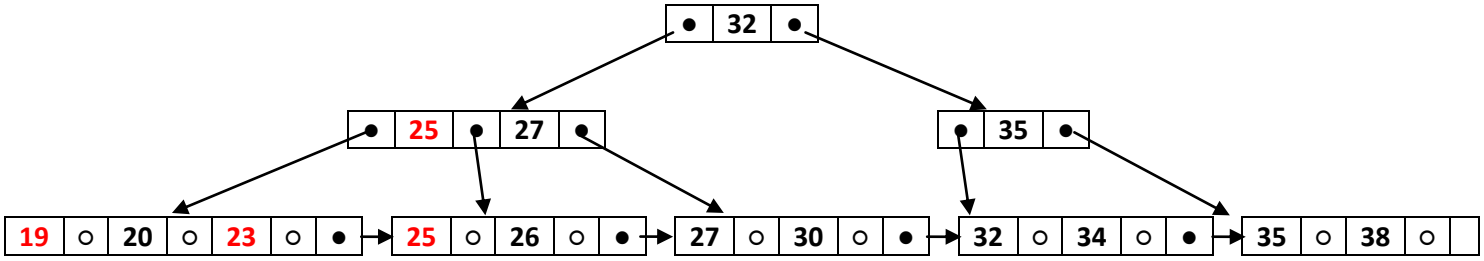
Εισαγωγή τιμής "19": Η τιμή **19** με την ίδια λογική τοποθετείται στον ίδιο κόμβο-φύλλο που τοποθετήθηκε και η τιμή **25.** Επειδή όμως η χωρητικότητα του κόμβου-φύλλου είναι 3 (n=3), η εισαγωγή της τιμής **19** θα προκαλέσει υπερχείλιση. Θα δημιουργηθεί ένας νέος κόμβος στον οποίο θα καταχωρηθούν οι τιμές **25** και **26,** ενώ ταυτόχρονα η τιμή **25** θα αντιγραφεί στον κόμβο-ρίζα μαζί με έναν δείκτη προς το νέο κόμβο.



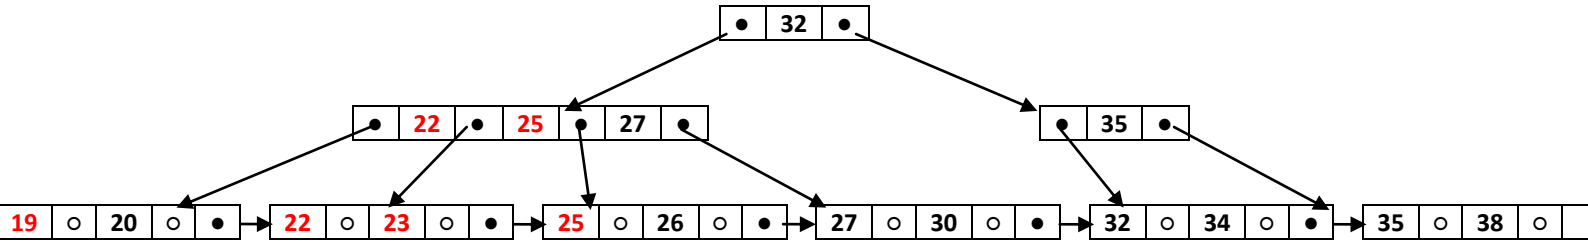
Επειδή η ρίζα του δέντρου περιέχει ήδη τρείς τιμές θα υπερχειλίσει. Ως αποτέλεσμα θα δημιουργηθεί ένας νέος κόμβος ο οποίος θα πάρει τις τιμές **32** και **35.** Στον νέο κόμβο χρειαζόμαστε μία τιμή και δύο δείκτες που θα δείχνουν στα φύλλα, οπότε η τιμή **32** μετακινείται ένα επίπεδο πάνω και δημιουργεί την ρίζα του δένδρου.



Ε**ισαγωγή τιμής "23":** Το 23 είναι μικρότερο του **32**, και μικρότερο του **25** οπότε θα τοποθετηθεί στο πρώτο αριστερό φύλλο και συγκριμένα μετά την τιμή **20** (23>20).



Ε**ισαγωγή τιμής "22": ":** Η τιμή **22** θα τοποθετηθεί στον πρώτο αριστερό κόμβο-φύλλο του δέντρου και συγκεκριμένα ανάμεσα στις τιμές **20** και **23**. Ο κόμβος-φύλλο θα υπερχειλίσει διότι θα περιέχει τέσσερις τιμές ενώ χωράει τρείς (n=3). Ως αποτέλεσμα θα δημιουργηθεί ένας νέος κόμβος στον οποίο θα καταχωρηθούν οι τιμές **22** και **23,** ενώ ταυτόχρονα η τιμή **22** θα αντιγραφεί στον κόμβο γονιό μαζί με έναν δείκτη προς τον νέο κόμβο.



Β) (key>=22 AND key<=34).

Περίπτωση1: Αν θεωρήσουμε ότι το κλειδί αναζήτησης key είναι μοναδικό τότε θα επισκεφτούμε 6 κόμβους**: [32] --> [22,25,27]-->[22,23]-->[25,26]-->[27,30]-->[32,34]**

Περίπτωση2: Αν θεωρήσουμε ότι το κλειδί αναζήτησης key δεν είναι μοναδικό (υπάρχουν διπλότυπα) τότε θα επισκεφτούμε 7 κόμβους **[32] --> [22,25,27]-->[22,23]-->[25,26]-->[27,30]-->[32,34]--> [35,38].**

Λύση Άσκησης 4

α) Υπολογισμός της τάξης των ενδιάμεσων κόμβων (P) και τάξης των φύλλων (PL)

Ένας εσωτερικός κόμβος του B+ δέντρου μπορεί να έχει **P** δείκτες δέντρου και p-1 τιμές πεδίου αναζήτησης. Όλα αυτά πρέπει να χωρούν σε ένα μπλοκ. Επομένως έχουμε:

(p * P) + (p -1) * N <=B

(7*P) + (P-1) *20 <= 2048 ==> 27*P-20<=2048 ==> 27*P <=2068 ==> **P=floor(2068/27)=76**

Οι κόμβοι-φύλλα του B+ δέντρου θα έχουν το ίδιο πλήθος τιμών και δεικτών, εκτός του ότι οι δείκτες είναι δείκτες δεδομένων και υπάρχει ένας δείκτης προς το επόμενο μπλοκ. Επομένως, η τάξη **PL** για τους κόμβους-φύλλα μπορεί να υπολογιστεί ως ακολούθως:

(PL *(q+N)) + p <=B

(PL * (9+20)) +7 <=2048 ==> 29*PL + 7 = 2048 ==>29*PL=2041 ==> **PL=floor(2041/29)=70**

Δηλαδή κάθε κόμβος φύλλο μπορεί να χωρέσει **PL=70** συνδυασμούς τιμής κλειδιού/δείκτη δεδομένων.

β) Πλήθος μπλοκ για τους κόμβους-φύλλα.

Με την υπόθεση ότι οι κόμβοι είναι πλήρεις κατά 70% κάθε κόμβος-φύλλο, κατά μέσο όρο, θα έχει =0,70*70=**49** δείκτες εγγραφών δεδομένων. Εφόσον το αρχείο έχει 200.000 εγγραφές, δηλαδή 200.000 διαφορετικά BARCODE, ο αριθμός των απαιτούμενων μπλοκ, για τους κόμβους-φύλλα είναι **ceiling (200000/49)=4082** μπλοκ.

γ) Πλήθος επιπέδων

Μπορούμε να υπολογίσουμε τον αριθμό των επιπέδων ως εξής:

Κατά μέσο όρο, κάθε εσωτερικός κόμβος θα έχει (0,70*P) = (0,70*76) = **54** δείκτες και επομένων **53** τιμές.

Αριθμός μπλοκ πρώτου επιπέδου = 4082
Αριθμός μπλοκ δευτέρου επιπέδου=(4082/54)=76
Αριθμός μπλοκ τρίτου επιπέδου = (76/54) = 2
Αριθμός μπλοκ τετάρτου επιπέδου=2/54 = 1

δ) Συνολικά μπλοκ

Συνολικά μπλοκ = 4082+76+2+1= 4161 blocks

ε) **Πλήθος προσπελάσεων**

Πλήθος προσπελάσεων = αριθμός επιπέδων + 1 = 4+1 =5.

Λύση Άσκησης 5

B#	(B MOD 8)	BINARY
6800	0	0000
7819	3	0011
8820	4	0100
6428	4	0100
7325	5	0101
8000	0	0000
6830	6	0110
8231	7	0111
6803	3	0011
5800	0	0000
5401	1	0001

1. Εισαγωγή 6800 (0000)

6800	
0	1

U=1/4 25%

2. Εισαγωγή 7819 (0011)

6800	7819
0	1

U=2/4 50%

3. Εισαγωγή 8820 (0100)

8820	
6800	7819
0	1

U=3/4 75%

Utilization =75%, ι αυξάνεται σε 2 και το m=2(10).

8820		
6800	7819	
00	*1	10

U=3/6 50%

4. Εισαγωγή 6428 (0100)

6428				
8820				
6800	**7819**		**U=4/8**	**50%**
00	***1**	**10**		

5. **Εισαγωγή 7325 (0101)**

6428				
8820	**7325**			
6800	**7819**		**U=5/8**	**63%**
00	***1**	**10**		

6. Εισαγωγή 8000 (0000)

8000				
6428				
8820	**7325**			
6800	**7819**		**U=6/8**	**75%**
00	***1**	**10**		

00	**01**	**10**	**11**

Utilization =75%, οπότε m=3(11).

8000					
6428					
8820					
6800	**7325**		**7819**	**U=6/10**	**60%**
00	**01**	**10**	**11**		

7. Εισαγωγή **6830 (0110)**

8000					
6428					
8820					
6800	**7325**	**6830**	**7819**	**U=7/10**	**70%**
00	**01**	**10**	**11**		

8. Εισαγωγή **8231** **(0111)**

8000					
6428					
8820			**8231**		
6800	**7325**	**6830**	**7819**	**U=8/10**	**80%**
00	**01**	**10**	**11**		

Utilization =80%, ι αυξάνεται σε 3 και το m=4(100).

8000			**8231**	**6428**		
6800	**7325**	**6830**	**7819**	**8820**	**U=8/10**	80%
000	***01**	***10**	***11**	**100**		

Utilization =80%, οπότε m=5(101).

8000			**8231**	**6428**			
6800		**6830**	**7819**	**8820**	**7325**	**U=8/12**	67%
000	**001**	***10**	***11**	**100**	**101**		

9. Εισαγωγή 6803 (0011)

			6803				
8000			**8231**	**6428**			
6800		**6830**	**7819**	**8820**	**7325**	**U=9/14**	64%
000	**001**	***10**	***11**	**100**	**101**		

10. Εισαγωγή 5800 (0000)

5800			**6803**				
8000			**8231**	**6428**			
6800		**6830**	**7819**	**8820**	**7325**	**U=10/16**	63%
000	**001**	***10**	***11**	**100**	**101**		

11. Εισαγωγή 5401 (0001)

5800			**6803**				
8000			**8231**	**6428**			
6800	**5401**	**6830**	**7819**	**8820**	**7325**	**U=11/16**	69%
000	**001**	***10**	***11**	**100**	**101**		

Β.

Μέσος αριθμός Προσπελάσεων όταν το κλειδί υπάρχει:

Έστω ότι αναζητούμε το κλειδί 6428. Το κλειδί υπάρχει στον κάδο 100 οπότε θα χρειαστούμε μία προσπέλαση. Αν όμως αναζητούμε το κλειδί 5800 θα πρέπει να προσπελάσουμε τον κάδο 000 και επειδή δεν υπάρχει σε αυτόν πρέπει να δούμε και την σελίδα υπερχείλισης (δεύτερη προσπέλαση).

Με το παραπάνω σκεπτικό 9 από τις 11 εγγραφές μπορούμε να τις εντοπίσουμε με μία μόνο προσπέλαση και τις υπόλοιπες 2 με δύο προσπελάσεις. Οπότε έχουμε:

(9*(1/11))+(2*(2/11) = 13/11 =1,18

Μέσος αριθμός Προσπελάσεων όταν το κλειδί δεν υπάρχει

Αν αναζητούμε τιμές που δεν υπάρχουν τότε εξετάζοντας τα 3 τελευταία bits το κόστος αναζήτησης θα είναι:

000 -> 2
001 -> 1
010 -> 1
011 -> 2
100 -> 1
101 -> 1
110 -> 1
111 -> 2

Δηλαδή 11/8=1,375