Σχεδιασμός Βάσεων Δεδομένων
Διδάσκων: Ιωάννης Κωτίδης

Εαρινό εξάμηνο 2022-2023

Ενδεικτικές Λύσεις Δεύτερης Σειράς Ασκήσεων

Λύση Άσκησης 1

Α) Αριθμός εγγραφών στην έξοδο: 1000000*(1/10000)*(500/1000)*(8/10)=40 εγγραφές.

Β) Χρησιμοποιώντας το ευρετήριο συστάδων που υπάρχει στα πεδία (A,B) θα ανακτήσουμε 1000000*(1/10000)*(500/1000)=50 εγγραφές οι οποίες χωράνε σε ceil(50/20)=3 σελίδες. Στη συνέχεια το φιλτράρισμα των εγγραφών που πληρούν το κριτήριο αναζήτησης F>2 μπορεί να γίνει στην μνήμη δίχως επιπλέον κόστος I/O.

Λύση Άσκησης 2

ΟΜΑΔΑ Α

Ε1: Ευρετήριο συστάδων, Β+δέντρο στο πεδίο Β

Είναι σημαντικό να βελτιστοποιήσουμε την εκτέλεση του Ε1 διότι έχει μεγάλη συχνότητα εκτέλεσης. Για τον λόγο αυτό θα δημιουργήσουμε ένα ευρετήριο συστάδων στο πεδίο Β. Το ευρετήριο πρέπει να έχει την δομή Β+δέντρου διότι το κριτήριο αναζήτησης αφορά εύρος τιμών (Β<?).

Ε2: Απλό Ευρετήριο κατακερματισμού στο πεδίο C

Για το Ε2 μπορούμε να δημιουργήσουμε ένα από ευρετήριο στο πεδίο C. Το πεδίο C έχει τουλάχιστον 1000 διακριτές τιμές οπότε το ευρετήριο αναμένουμε ότι θα επιταχύνει την εκτέλεση του Ε2. Το ευρετήριο θα πρέπει να είναι κατά προτίμηση ευρετήριο κατακερματισμού λόγω της ισότητας (C=?). Ωστόσο κατάλληλο είναι και ένα ευρετήριο Β+δέντρου.

ΟΜΑΔΑ Β

Ε1: Ευρετήριο συστάδων, Β+δέντρο στα πεδία (C,B)

Ένα ευρετήριο συστάδων Β+δέντρου στα πεδία (C,B) είναι το πλέον κατάλληλο διότι μπορεί να αξιοποιηθεί ώστε να εντοπιστούν οι εγγραφές που πληρούν και τα δύο κριτήρια αναζήτησης.

Ε2:Απλό Ευρετήριο Κατακερματισμού στο πεδίο D

Εφόσον μπορούμε να δημιουργήσουμε μόνο ένα ευρετήριο επιλέγουμε να το αξιοποιήσουμε ώστε να επιταχύνουμε την εκτέλεση του Ε2 διότι έχει σημαντικά

μεγαλύτερη συχνότητα εκτέλεσης από το Ε3. Το ευρετήριο θα πρέπει να είναι κατά προτίμηση ευρετήριο κατακερματισμού λόγω της ισότητας (D=?). Ωστόσο κατάλληλο είναι και ένα ευρετήριο B+δέντρου.

ΟΜΑΔΑ Γ

Ε1: Απλό ευρετήριο, B+δέντρο στο πεδίο (B) με Included τα πεδία (A,C)

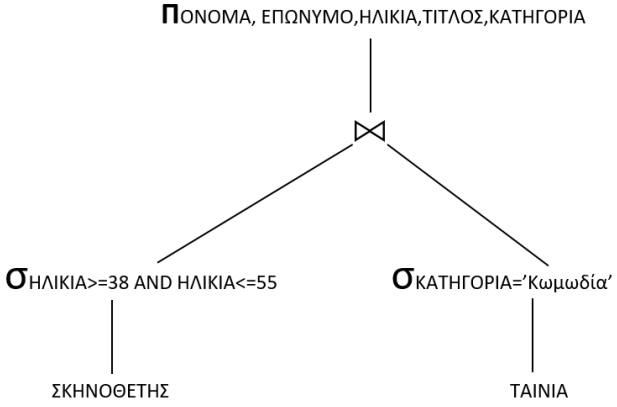
Επειδή το Ε1 εμφανίζει μόνο τα πεδία Α και C το προτεινόμενο ευρετήριο μπορεί να αξιοποιηθεί για να απαντηθεί το ερώτημα δίχως να προσπελαστούν οι εγγραφές του πίνακα (cover index).

Ε2: Ευρετήριο συστάδων, B+δέντρο στο πεδίο D

Το ευρετήριο πρέπει να έχει την δομή B+δέντρου διότι το κριτήριο αναζήτησης αφορά εύρος τιμών (D<?).

Λύση Άσκησης 3

Α) Λογικό Πλάνο



Β)

Από τα δεδομένα της άσκησης έχουμε ότι:

- Τ(ΣΚΗΝΟΘΕΤΗΣ)=4000 και Β(ΣΚΗΝΟΘΕΤΗΣ)=4000/40=100
- Τ(ΤΑΙΝΙΑ)=20000 και Β(ΤΑΙΝΙΑ)=20000/20=1000
- V(ΤΑΙΝΙΑ,ΚΑΤΗΓΟΡΙΑ)=10

Έστω ότι Χ=σ(ΗΛΙΚΙΑ>=38 AND ΗΛΙΚΙΑ<=55)ΣΚΗΝΟΘΕΤΗΣ και Υ=σ(ΚΑΤΗΓΟΡΙΑ='Κωμωδία')ΤΑΙΝΙΑ

Με βάση το ιστόγραμμα στο πεδίο ηλικία έχουμε:
Τ(Χ)=(2/10*1000) + (10/10*1500) + (6/10*500) = 200+1500+300=2000.
Β(Χ)=2000/40=50

Το κόστος υπολογισμού του Χ με table scan είναι Β(ΣΚΗΝΟΘΕΤΗΣ)=100 ενώ με την χρήση του ευρετηρίου συστάδων στο πεδίο ΣΚΗΝΟΘΕΤΗΣ.ΗΛΙΚΙΑ είναι Β(Χ)=50. Επιλέγουμε το μικρότερο οπότε κόστος cost(X)=50.

Επειδή V(ΤΑΙΝΙΑ, ΚΑΤΗΓΟΡΙΑ)=10 έχουμε:
T(Y)=20000/10=2000 και B(Y)=2000/20=100

Το κόστος υπολογισμού του Υ με table scan είναι Β(ΤΑΙΝΙΑ)=1000 ενώ με την χρήση του απλού ευρετηρίου στο πεδίο ΤΑΙΝΙΑ.ΚΑΤΗΓΟΡΙΑ είναι Τ(Υ)=2000. Επιλέγουμε το μικρότερο οπότε κόστος cost(Y)=1000.

Κόστος SMJ
Δεδομένου ότι η διαθέσιμη μνήμη είναι M=16 ισχύει ότι M^2 >= B(X) + B(Y) (16*16>50+100) μπορούμε να εφαρμόσουμε την αποδοτική έκδοση του αλγορίθμου:
cost(SMJ)=cost(X)+cost(Y) + 2*B(X)+2*B(Y)= 50+1000+ 2*50 + 2*100 = 1350 I/O.

Κόστος NLJ με εξωτερική την σχέση Χ
cost(NLJ)=cost(X) + ceil(B(X)/M-1)*cost(Y)=50 + ceil(50/15)*1000=50+4*1000=4050 I/O.

Κόστος NLJ με εξωτερική την σχέση Υ
cost(NLJ)=cost(Y) + ceil(B(Y)/M-1)*cost(X)=1000 + ceil(100/15)*50=1000 +7*50=1350 I/O.

Λύση Άσκησης 4

Α)

Κόστος Βήματος 1: 100 I/0

Από τα δεδομένα της άσκησης έχουμε Τ(ΜΑΘΗΤΕΣ)=1200, Β(ΜΑΘΗΤΕΣ)=100 και V(ΜΑΘΗΤΕΣ,ΠΕΔΙΟ)=4. Το κόστος για το διάβασμα της σχέσης ΜΑΘΗΤΕΣ(table scan) είναι **100 I/O** και το αποτέλεσμα της επιλογής είναι 1200/4=**300 εγγραφές** δηλαδή 300/12=**25 σελίδες** (σε μία σελίδα χωράνε 1200/100=12 εγγραφές της σχέσης ΜΑΘΗΤΕΣ).

Κόστος Βήματος 2: 120 I/O

Από τα δεδομένα της άσκησης έχουμε Τ(ΣΧΟΛΕΙΑ)=600, Β(ΣΧΟΛΕΙΑ)=120. Το κόστος για το διάβασμα της σχέσης ΣΧΟΛΕΙΑ **είναι 120 I/O.** Το αποτέλεσμα της επιλογής είναι **30 εγγραφές** (5/100*600 διότι το 5% των σχολείων είναι ιδιωτικά) οι οποίες χωράνε σε **6 σελίδες** (σε μία σελίδα χωράνε 600/120=5 εγγραφές της σχέσης ΣΧΟΛΕΙΑ).

Κόστος Βήματος 3: 112 I/O.

Η είσοδος στον τελεστή ισοσύνδεσης είναι 31 σελίδες (25 + 6). Οι 25 σελίδες έρχονται από την έξοδο της επιλογής $\sigma_{\text{ΠΕΔΙΟ=4}}$ **έστω X** και 6 σελίδες από την έξοδο της επιλογής

$\sigma_{\text{ΚΑΤΗΓΟΡΙΑ='Ιδιωτικό'}}$ **έστω Y**

Επειδή η διαθέσιμη μνήμη είναι **M=5** ισχύει ότι: **M>=SQRT(max(25, 6))** οπότε το κόστος του SMJ υπολογίζεται ως εξής:

Για το **X** θα δημιουργηθούν 5 υπολίστες οι οποίες θα γραφούν στον δίσκο. Στην συνέχεια θα διαβαστούν και θα συγχωνευθούν σε μία η οποία και θα γραφεί στον δίσκο. Οπότε μέχρι στιγμής έχουμε **3*B(X).**

Για το Y θα δημιουργηθούν δύο υπολίστες οι οποίες θα γραφούν στον δίσκο. Κόστος **B(Y).**

Στην φάση της συγχώνευσης θα διαβαστεί η μία λίστα για το X και οι δύο λίστες για το Y δηλαδή κόστος B(X) + B(Y). Συνεπώς:

COST(SMJ)=4*B(X) +2*B(Y)=4*25+2*6=112.

Στην συγκεκριμένη περίπτωση πρόκειται για ισοσύνδεση μεταξύ πρωτεύοντος και ξένου κλειδιού δηλαδή κάθε εγγραφή της σχέσης ΜΑΘΗΤΕΣ αντιστοιχεί **σε μία** εγγραφή της σχέσης ΣΧΟΛΕΙΑ. Έχουν προηγηθεί οι επιλογές με βάση το επιστημονικό πεδίο και την κατηγορία του σχολείου οι οποίες όμως είναι μεταξύ τους ανεξάρτητες και μόνο 5% των μαθητών αντιστοιχούν σε κάποιο ιδιωτικό σχολείο (300*30/600) = **15.**

Κόστος Βήματος 4: 150 I/O.

Για κάθε μια από τις 15 εγγραφές που δέχεται ως είσοδο, ο αλγόριθμος INLJ χρησιμοποιεί το ευρετήριο που υπάρχει στο πεδίο ΑΜ της σχέσης ΔΗΛΩΣΕΙΣ για να εντοπίσει και να ανακτήσει τις αντίστοιχες εγγραφές της σχέσης ΔΗΛΩΣΕΙΣ (look-up/probe). Δεδομένου ότι κάθε μαθητής μπορεί να δηλώσει το πολύ σε 10 τμήματα, για κάθε ΑΜ θα ανακτηθούν το πολύ 10 εγγραφές της σχέσης ΔΗΛΩΣΕΙΣ. Αν υποθέσουμε ότι αυτές οι εγγραφές βρίσκονται σε διαφορετικές σελίδες τότε για κάθε μία από τις 15 εγγραφές φοιτητών θα διαβάσει το πολύ 10 σελίδες . Άρα το συνολικό κόστος είναι 15*10=**150 σελίδες.**

Κόστος Βήματος 5: 0 I/O.

On the fly

Κόστος Βήματος 6: 0 I/O.

On the fly

Συνολικό Κόστος: **100+120+112+150 = 482 σελίδες**

Β) Μνήμη Μ=32 σελίδες και ευρετήριο συστάδων στο πεδίο ΔΗΛΩΣΕΙΣ.ΑΜ

Αν το μέγεθος της μνήμης είναι 32 σελίδες τότε το κόστος του **SMJ (Βήμα 3) είναι 0 (μηδέν) I/0**, διότι οι 31 σελίδες (25+6) που δέχεται στην είσοδο ο αλγόριθμος χωράνε στην μνήμη.

Αν το ευρετήριο στο πεδίο ΑΜ είναι ευρετήριο συστάδων (clustered index) τότε για κάθε έναν από τους 15 μαθητές θα διαβάσει μια σελίδα διότι 10 εγγραφές της σχέσης ΔΗΛΩΣΕΙΣ χωράνε σε μία σελίδα (μία σελίδα της σχέσης ΔΗΛΩΣΕΙΣ χωράει (12000/400=300 εγγραφές) οπότε το κόστος θα είναι **15 I/O.**

Συνολικό Κόστος: **100+120+0+15 = 235 σελίδες**

Λύση Άσκησης 5

Α) Το αποτέλεσμα της σύζευξης των σχέσεων R και S είναι 1000 εγγραφές διότι:

- Το πεδίο S.C είναι πρωτεύον κλειδί.
- Το πεδίο R.C είναι ξένο κλειδί το οποίο αναφέρεται στο πεδίο S.C και δεν δέχεται τιμές NULL.

Παρομοίως η σύζευξη του αποτελέσματος R⋈S με την σχέση W θα 1000 εγγραφές διότι:

- Το πεδίο W.E είναι πρωτεύον κλειδί.
- Το πεδίο S.E είναι ξένο κλειδί το οποίο αναφέρεται στο πεδίο W.E και δεν δέχεται τιμές NULL.

Β) Υπολογισμός Κόστους.

Για κάθε εγγραφή της σχέσης R εκτελούμε τα παρακάτω βήματα:

1. Χρησιμοποιούμε το ευρετήριο που υπάρχει στο πεδίο S.C για να ανακτήσουμε την μοναδική εγγραφή για την οποία ισχύει ότι R.C=S.C. Συνεπώς για κάθε εγγραφή της σχέσης R θα διαβάσουμε μία σελίδα της σχέσης S.
2. Χρησιμοποιούμε το ευρετήριο που υπάρχει στο πεδίο W.E για να ανακτήσουμε την μοναδική εγγραφή για την οποία ισχύει ότι S.E=W.E. Συνεπώς για κάθε εγγραφή της σχέσης R θα διαβάσουμε μία σελίδα της σχέσης E.

Βάση των παραπάνω για κάθε εγγραφή της σχέσης R θα διαβάσουμε 2 σελίδες άρα θα διαβάσουμε συνολικά 1000*2=2000 σελίδες. Σε αυτές πρέπει να προσθέσουμε και το κόστος για το διάβασμα της σχέσης R η οποία είναι B(R)=100 σελίδες.

Συνολικό κόστος = 2000+100=2100 σελίδες.

C) Η δημιουργία ενός ευρετηρίου συστάδων στο πεδίο R.C μπορεί να επιταχύνει σημαντικά τον εκτέλεση της σύζευξης στην περίπτωση που το πεδίο R.C περιέχει μεγάλο αριθμό διπλότυπων. Εξαιτίας του ευρετηρίου οι εγγραφές της σχέσης R θα εισέρχονται στην είσοδο του τελεστή σύζευξης ταξινομημένες ως προς το πεδίο R.C. Με τον τρόπο αυτό διαδοχικές εγγραφές με την ίδια τιμή στο πεδίο R.C θα ανακτούν τις ίδιες σελίδες από τις σχέσεις S και W οπότε το κόστος I/O θα μειωθεί σημαντικά. Αρκεί η διαθέσιμη μνήμη να είναι τουλάχιστον τρείς σελίδες M=3 ώστε να χωράει την τρέχουσα σελίδα της R και τις δύο σελίδες που ανακτούμε για κάθε εγγραφή της R (μία από την σχέση S και μια από την σχέση W). Στην συγκεκριμένη περίπτωση επειδή V(R,C)=125 το κόστος για τον υπολογισμό της σύζευξης θα είναι **2*125+100= 350 σελίδες.**