ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2025 – 2026
ΜΑΘΗΜΑ: Συστήματα Ανάκτησης Πληροφοριών
Προγραμματιστική εργασία: Σημασιολογική ανάκτηση

## Φάση 1 – Baseline – Κλασική ανάκτηση

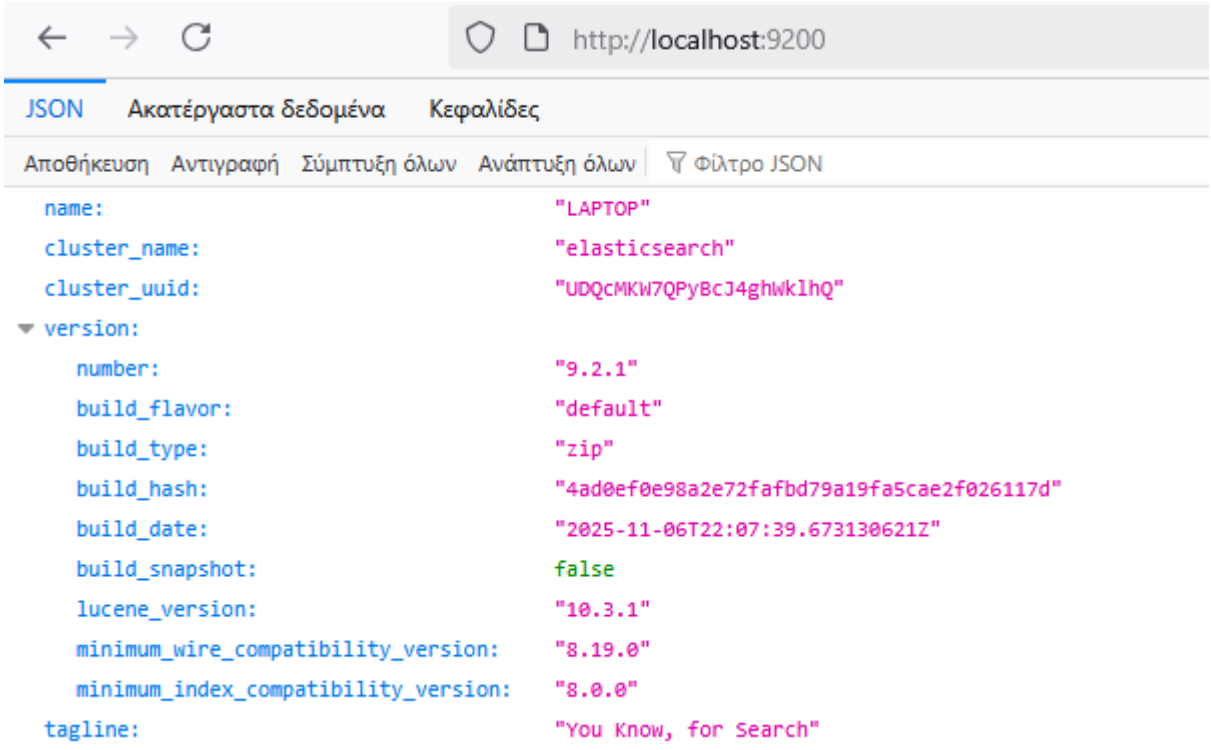
### Προετοιμασία:

- ElasticSearch

Για τις ανάγκες της άσκησης πρέπει να χρησιμοποιήσουμε την μηχανή αναζήτησης ElasticSearch. Έτσι επισκεπτόμαστε την σελίδα των downloads:
https://www.elastic.co/downloads/elasticsearch
και κατεβάζουμε το αρχείο .zip για Windows, στη συνέχεια αποσυμπιέζουμε το zip κάπου, π.χ. C:\elasticsearch\

Για να μην μας ζητάει username και password κάθε φορά που εκτελούμε το elastisearch, επεξεργαζόμαστε (με Notepad/Notepad++) το αρχείο elasticsearch.yml που βρίσκεται μέσα στον φάκελο config, και θέτουμε: **xpack.security.enabled: false**

Στην συνέχεια πηγαίνουμε στον φάκελο bin και εκτελούμε το αρχείο **elasticsearch.bat**. Μετά από λίγα δευτερόλεπτα θα ξεκινήσει ο server. Για να επαληθεύσουμε ότι τρέχει ανοίγουμε τον browser και πηγαίνουμε στην διεύθυνση:
http://localhost:9200/
όπου βλέπουμε ένα JSON με τις πληροφορίες της έκδοσης:



- track_eval

Για τις ανάγκες της άσκησης πρέπει να χρησιμοποιήσουμε το εργαλείο αξιολόγησης track_eval. Χρησιμοποιήσαμε το έτοιμο εκτελέσιμο αρχείο trec_eval.exe που δίνεται στο eclass.

- Υλοποίηση

Το περιβάλλον υλοποίησης είναι το Jupyter Notebook με Python, ακολουθώντας τη μεθοδολογία που παρουσιάστηκε στα εργαστήρια του μαθήματος.

## 1. Προεπεξεργασία

Δεν εφαρμόσαμε καμία χειροκίνητη γλωσσολογική προεπεξεργασία (π.χ. NLTK) στα έγγραφα της συλλογής IR2025. Ο λόγος είναι ότι επιλέχθηκε η χρήση του **ενσωματωμένου English Analyzer** του ElasticSearch (όπως προτάθηκε και στο βίντεο του Εργαστηρίου 2), ο οποίος αναλαμβάνει πλήρως την ανάλυση των κειμένων στη φάση του indexing και του querying.

Ο English analyzer εκτελεί αυτόματα: μετατροπή σε πεζά (lowercasing), tokenization μέσω του standard tokenizer, αφαίρεση αγγλικών stopwords, stemming.

Φορτώνουμε αυτούσιο το κείμενο της συλλογής, και όλη η ουσιαστική γλωσσική προεπεξεργασία θα πραγματοποιηθεί από το Elasticsearch τόσο για τα documents όσο και για τα queries.

Κατά συνέπεια, η συλλογή κειμένων βρίσκεται σε κατάλληλη μορφή για την εφαρμογή του αλγορίθμου BM25 και την εκτέλεση των queries της εργασίας.

## 2. Δημιουργία Ευρετηρίου (Indexing) στο ElasticSearch

Στόχος είναι να φτιάξουμε index στο ElasticSearch και να βάλουμε μέσα τα κείμενα του IR2025. Το υλοποιήσαμε με τον ίδιο τρόπο όπως στο αρχείο "phase1_example_solution.ipynb", το ευρετήριο λέγεται **ir2025_index** και έχει πεδία id, text.

Φτιάξαμε ένα πολύ απλό mapping:

- id: integer (για doc id)
- text: text (για το κείμενο), χρησιμοποιεί τον English Analyzer
- συνάρτηση ομοιότητας: BM25Similarity, με παραμέτρους k1 = 1.2 και b = 0.75. Οι παράμετροι αυτές σύμφωνα με την βιβλιογραφία είναι τυπικές τιμές που προσφέρουν ισορροπία ανάμεσα στη συχνότητα όρων και το μήκος των εγγράφων.

Το indexing έγινε μέσω της Python χρησιμοποιώντας το: from elasticsearch.helpers import bulk

## 3. Εκτέλεση ερωτημάτων & παραγωγή run files για το trec_eval

Αφού ολοκληρώσαμε την διαδικασία indexing της συλλογής IR2025, πραγματοποιήσαμε την εκτέλεση των ερωτημάτων (queries) της εργασίας μέσω του μηχανισμού αναζήτησης του ElasticSearch. Τα queries φορτώθηκαν από το αρχείο queries.csv, χωρίς χειροκίνητη γλωσσική προεπεξεργασία, καθώς η ανάλυση (tokenization, stopwords, stemming) πραγματοποιείται από τον English Analyzer του index.

Η συνάρτηση "run_all_queries_and_write_trec(k: int, run_name: str)", τρέχει όλα τα queries και γράφει τις απαντήσεις σε TREC format:

Τρέχουμε αυτή τη συνάρτηση και για τα τρία k (k=20, k=30, k=50) και τα αποτελέσματα τα αποθηκεύουμε σε τρία αρχεία αντίστοιχα: **bm25_k20.txt**, **bm25_k30.txt**, **bm25_k50.txt**.

**4.** Αξιολόγηση απαντήσεων χρησιμοποιώντας το trec_eval

Έχοντας τα προηγούμενα τρία αρχεία (bm25_k20.txt, bm25_k30.txt, bm25_k50.txt) και το αρχείο με τις σωστές απαντήσεις (qrels.txt) στον ίδιο φάκελο με το trec_eval.exe, εκτελούμε, σε περιβάλλον cmd, τις εντολές:
trec_eval.exe qrels.txt bm25_k20.txt >phase1_results_k20.txt
trec_eval.exe qrels.txt bm25_k30.txt > phase1_results_k30.txt
trec_eval.exe qrels.txt bm25_k50.txt > phase1_results_k50.txt

οι οποίες στέλνουν τα αποτελέσματα των εκτελέσεων στα αρχεία **phase1_results_k20.txt**, **phase1_results_k30.txt** και **phase1_results_k50.txt**, για να τις έχουμε διαθέσιμες για περαιτέρω επεξεργασία.

Τα περιεχόμενα των παραπάνω αρχείων είναι:

| **phase1_results_k20.txt** | | **phase1_results_k30.txt** | | **phase1_results_k50.txt** | |
|---|---|---|---|---|---|
| runid | all bm25_k20 | runid | all bm25_k30 | runid | all bm25_k50 |
| num_q | all 10 | num_q | all 10 | num_q | all 10 |
| num_ret | all 200 | num_ret | all 300 | num_ret | all 500 |
| num_rel | all 152 | num_rel | all 152 | num_rel | all 152 |
| num_rel_ret | all 126 | num_rel_ret | all 141 | num_rel_ret | all 149 |
| map | all 0.6895 | map | all 0.7471 | map | all 0.7701 |
| gm_map | all 0.6832 | gm_map | all 0.7410 | gm_map | all 0.7634 |
| Rprec | all 0.7130 | Rprec | all 0.7130 | Rprec | all 0.7130 |
| bpref | all 0.8214 | bpref | all 0.9209 | bpref | all 0.9757 |
| recip_rank | all 0.9500 | recip_rank | all 0.9500 | recip_rank | all 0.9500 |
| iprec_at_recall_0.00 | all 0.9875 | iprec_at_recall_0.00 | all 0.9875 | iprec_at_recall_0.00 | all 0.9875 |
| iprec_at_recall_0.10 | all 0.9875 | iprec_at_recall_0.10 | all 0.9875 | iprec_at_recall_0.10 | all 0.9875 |
| iprec_at_recall_0.20 | all 0.9708 | iprec_at_recall_0.20 | all 0.9708 | iprec_at_recall_0.20 | all 0.9708 |
| iprec_at_recall_0.30 | all 0.9048 | iprec_at_recall_0.30 | all 0.9048 | iprec_at_recall_0.30 | all 0.9048 |
| iprec_at_recall_0.40 | all 0.8302 | iprec_at_recall_0.40 | all 0.8302 | iprec_at_recall_0.40 | all 0.8302 |
| iprec_at_recall_0.50 | all 0.8227 | iprec_at_recall_0.50 | all 0.8227 | iprec_at_recall_0.50 | all 0.8227 |
| iprec_at_recall_0.60 | all 0.7858 | iprec_at_recall_0.60 | all 0.7858 | iprec_at_recall_0.60 | all 0.7858 |
| iprec_at_recall_0.70 | all 0.7535 | iprec_at_recall_0.70 | all 0.7535 | iprec_at_recall_0.70 | all 0.7535 |
| iprec_at_recall_0.80 | all 0.5292 | iprec_at_recall_0.80 | all 0.6655 | iprec_at_recall_0.80 | all 0.6655 |
| iprec_at_recall_0.90 | all 0.0650 | iprec_at_recall_0.90 | all 0.4684 | iprec_at_recall_0.90 | all 0.5300 |
| iprec_at_recall_1.00 | all 0.0000 | iprec_at_recall_1.00 | all 0.1794 | iprec_at_recall_1.00 | all 0.4166 |
| P_5 | all 0.8800 | P_5 | all 0.8800 | P_5 | all 0.8800 |
| P_10 | all 0.7300 | P_10 | all 0.7300 | P_10 | all 0.7300 |
| P_15 | all 0.7000 | P_15 | all 0.7000 | P_15 | all 0.7000 |
| P_20 | all 0.6300 | P_20 | all 0.6300 | P_20 | all 0.6300 |
| P_30 | all 0.4200 | P_30 | all 0.4700 | P_30 | all 0.4700 |
| P_100 | all 0.1260 | P_100 | all 0.1410 | P_100 | all 0.1490 |
| P_200 | all 0.0630 | P_200 | all 0.0705 | P_200 | all 0.0745 |
| P_500 | all 0.0252 | P_500 | all 0.0282 | P_500 | all 0.0298 |
| P_1000 | all 0.0126 | P_1000 | all 0.0141 | P_1000 | all 0.0149 |

Από τα περιεχόμενα των παραπάνω αρχείων έχουμε:

| k | MAP | Precision@5 | Precision@10 | Precision@15 | Precision@20 |
|---|---|---|---|---|---|
| 20 | 0.6895 | 0.8800 | 0.7300 | 0.7000 | 0.6300 |
| 30 | 0.7471 | 0.8800 | 0.7300 | 0.7000 | 0.6300 |
| 50 | 0.7701 | 0.8800 | 0.7300 | 0.7000 | 0.6300 |

Όπως φαίνεται από τον παραπάνω πίνακα, η συνάρτηση ομοιότητας BM25Similarity παρουσιάζει υψηλή ποιότητα ανάκτησης στις πρώτες θέσεις, όπως φαίνεται από τις τιμές Precision@5 = 0.80 και Precision@10 = 0.74.

Το MAP (mean average precision) αυξάνεται σταθερά όσο αυξάνεται το k, γεγονός που δείχνει ότι το σύστημα ανακτά περισσότερα σχετικά κείμενα όταν αυξάνεται το βάθος της αναζήτησης.

Οι τιμές Precision@5 – Precision@20 παραμένουν σταθερές για όλα τα k, κάτι που δείχνει ότι η ακρίβεια στα κορυφαία αποτελέσματα είναι σταθερή ανεξάρτητα από το βάθος ανάκτησης.

**5.** Πηγές

https://www.elastic.co/docs/solutions/search/get-started

https://trec.nist.gov/trec_eval/index.html

https://en.wikipedia.org/wiki/Okapi_BM25