ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2025 – 2026
ΜΑΘΗΜΑ: Συστήματα Ανάκτησης Πληροφοριών
Προγραμματιστική εργασία: Σημασιολογική ανάκτηση

Φάση 2 – Σημασιολογική ανάκτηση χρησιμοποιώντας Transformers και FAISS

Στόχος

Στόχος της Φάσης 2 είναι η υλοποίηση ενός συστήματος **σημασιολογικής** ανάκτησης πληροφορίας, το οποίο βασίζεται σε ενθέσεις (embeddings) που παράγονται από προεκπαιδευμένο transformer μοντέλο.

Σε αντίθεση με τη Φάση 1 (BM25), όπου η ανάκτηση βασίζεται σε όρους και συχνότητες, εδώ η ομοιότητα υπολογίζεται στον χώρο των διανυσματικών αναπαραστάσεων.

Το σύστημα υλοποιήθηκε με χρήση:

- Του προεκπαιδευμένου μοντέλλου all-MiniLM-L6-v2 από την βιβλιοθήκη transformer, για παραγωγή ενθέσεων (embeddings)
- Της βιβλιοθήκης FAISS για αποδοτική αναζήτηση κοντινότερων γειτόνων
- Του εργαλείου trec_eval για αξιολόγηση. Χρησιμοποιήσαμε το έτοιμο εκτελέσιμο αρχείο trec_eval.exe που δίνεται στο eclass.

1. Δεδομένα - Προεπεξεργασία

Χρησιμοποιήθηκαν τα ίδια δεδομένα με τη Φάση 1, ώστε τα αποτελέσματα να είναι άμεσα συγκρίσιμα:

- documents.csv, με πεδία ID και Text
- queries.csv, με πεδία ID και Text
- qrels, για την αξιολόγηση της συνάφειας

Δεν εφαρμόστηκε επιπλέον προεπεξεργασία κειμένου (stemming, stopword removal κ.λπ.), καθώς τα transformer μοντέλα είναι σχεδιασμένα να επεξεργάζονται απευθείας το φυσικό κείμενο.

2. Προεκπαιδευμένο Μοντέλο

Για την παραγωγή των διανυσματικών αναπαραστάσεων - ενθέσεων (embeddings) επιλέχθηκε το μοντέλο **all-MiniLM-L6-v2**. Το μοντέλο αυτό παράγει ενθέσεις διαστάσεων 384, και είναι κατάλληλο για sentence-level semantic similarity, ενώ παραμένει αποδοτικό σε εκτέλεση σε CPU.

Για κάθε έγγραφο και κάθε ερώτημα υπολογίστηκε ένα embedding, το οποίο κανονικοποιήθηκε με L2 normalization. Η κανονικοποίηση αυτή επιτρέπει τη χρήση συνημιτονοειδούς ομοιότητας (cosine similarity) μέσω εσωτερικού γινομένου των διανυσμάτων – ενθέσεων.

3. Κατασκευή Ευρετηρίου FAISS

Για την αναζήτηση χρησιμοποιήθηκε η βιβλιοθήκη FAISS. Οι ενθέσεις των εγγράφων αποθηκεύτηκαν σε FAISS index τύπου IndexFlatIP ((inner product). Το ευρετήριο (index) κατασκευάζεται μία φορά από τις ενθέσεις των εγγράφων, αποθηκεύεται στον δίσκο (με όνομα doc_embeddings.npy) και χρησιμοποιείται για όλα τα ερωτήματα (queries).

4. Διαδικασία Ανάκτησης

Για κάθε ερώτημα (query) ακολουθήθηκαν τα εξής βήματα:

i. Υπολογισμός embedding του query
ii. Αναζήτηση στο FAISS index
iii. Ανάκτηση των top-k εγγράφων με βάση τη σημασιολογική ομοιότητα

Η διαδικασία επαναλήφθηκε για k = 20, k = 30 και k = 50

Για κάθε περίπτωση δημιουργήθηκε αρχείο αποτελεσμάτων σε μορφή TREC, συμβατή με το εργαλείο trec_eval

Η συνάρτηση `write_run_file(k: int, run_name: str)`, τρέχει όλα τα queries και γράφει τις απαντήσεις σε TREC format:

Τρέχουμε αυτή τη συνάρτηση και για τα τρία k (k=20, k=30, k=40) και τα αποτελέσματα τα αποθηκεύουμε μέσα στον φάκελο runs_phase2, σε τρία αρχεία αντίστοιχα: **run_k20.txt**, **run_k30.txt**, **run_k50.txt**.

5. Αξιολόγηση

Η αξιολόγηση πραγματοποιήθηκε με το εργαλείο trec_eval, χρησιμοποιώντας τα ίδια qrels με τη Φάση 1. Έχοντας τα προηγούμενα τρία αρχεία (run_k20.txt, run_k30.txt, run_k50.txt) και το αρχείο με τις σωστές απαντήσεις (qrels.txt) στον ίδιο φάκελο με το trec_eval.exe, εκτελούμε, σε περιβάλλον cmd, τις εντολές:

trec_eval.exe qrels.txt run_k20.txt > phase2_results_k20.txt
trec_eval.exe qrels.txt run_k30.txt > phase2_results_k30.txt
trec_eval.exe qrels.txt run_k50.txt > phase2_results_k50.txt

οι οποίες στέλνουν τα αποτελέσματα των εκτελέσεων στα αρχεία **phase2_results_k20.txt**, **phase2_results_k30.txt** και **phase2_results_k50.txt**, για να τις έχουμε διαθέσιμες για περαιτέρω επεξεργασία.

Τα περιεχόμενα των παραπάνω αρχείων είναι:

phase2_results_k20.txt

```
runid     all minilm_faiss_cos_k20
num_q     all 10
num_ret   all 200
num_rel   all 152
num_rel_ret   all 70
map   all 0.3129
gm_map   all 0.2914
Rprec   all 0.3909
bpref   all 0.4447
recip_rank   all 0.9500
iprec_at_recall_0.00   all 0.9556
iprec_at_recall_0.10   all 0.8206
```

phase2_results_k30.txt

```
runid     all minilm_faiss_cos_k30
num_q     all 10
num_ret   all 300
num_rel   all 152
num_rel_ret   all 83
map   all 0.3413
gm_map   all 0.3194
Rprec   all 0.3909
bpref   all 0.5320
recip_rank   all 0.9500
iprec_at_recall_0.00   all 0.9556
iprec_at_recall_0.10   all 0.8206
```

phase2_results_k50.txt

```
runid     all minilm_faiss_cos_k50
num_q     all 10
num_ret   all 500
num_rel   all 152
num_rel_ret   all 103
map   all 0.3744
gm_map   all 0.3501
Rprec   all 0.3909
bpref   all 0.6626
recip_rank   all 0.9500
iprec_at_recall_0.00   all 0.9556
iprec_at_recall_0.10   all 0.8206
```

iprec_at_recall_0.20	all 0.7535	iprec_at_recall_0.20	all 0.7559	iprec_at_recall_0.20	all 0.7559
iprec_at_recall_0.30	all 0.5257	iprec_at_recall_0.30	all 0.5439	iprec_at_recall_0.30	all 0.5439
iprec_at_recall_0.40	all 0.3854	iprec_at_recall_0.40	all 0.4075	iprec_at_recall_0.40	all 0.4394
iprec_at_recall_0.50	all 0.2354	iprec_at_recall_0.50	all 0.3572	iprec_at_recall_0.50	all 0.3724
iprec_at_recall_0.60	all 0.0684	iprec_at_recall_0.60	all 0.1429	iprec_at_recall_0.60	all 0.2623
iprec_at_recall_0.70	all 0.0000	iprec_at_recall_0.70	all 0.0000	iprec_at_recall_0.70	all 0.1561
iprec_at_recall_0.80	all 0.0000	iprec_at_recall_0.80	all 0.0000	iprec_at_recall_0.80	all 0.0672
iprec_at_recall_0.90	all 0.0000	iprec_at_recall_0.90	all 0.0000	iprec_at_recall_0.90	all 0.0000
iprec_at_recall_1.00	all 0.0000	iprec_at_recall_1.00	all 0.0000	iprec_at_recall_1.00	all 0.0000
P_5	all 0.6600	P_5	all 0.6600	P_5	all 0.6600
P_10	all 0.5000	P_10	all 0.5000	P_10	all 0.5000
P_15	all 0.3933	P_15	all 0.3933	P_15	all 0.3933
P_20	all 0.3500	P_20	all 0.3500	P_20	all 0.3500
P_30	all 0.2333	P_30	all 0.2767	P_30	all 0.2767
P_100	all 0.0700	P_100	all 0.0830	P_100	all 0.1030
P_200	all 0.0350	P_200	all 0.0415	P_200	all 0.0515
P_500	all 0.0140	P_500	all 0.0166	P_500	all 0.0206
P_1000	all 0.0070	P_1000	all 0.0083	P_1000	all 0.0103

Από τα περιεχόμενα των παραπάνω αρχείων έχουμε:

k	MAP	Precision@5	Precision@10	Precision@15	Precision@20
20	0.3129	0.6600	0.5000	0.3933	0.3500
30	0.3413	0.6600	0.5000	0.3933	0.3500
50	0.3744	0.6600	0.5000	0.3933	0.3500

Όπως φαίνεται από τον παραπάνω πίνακα, το MAP (mean average precision) αυξάνεται όσο αυξάνεται το k (από 0.3129 για k=20 σε 0.3744 για k=50), γεγονός που οφείλεται στην ανάκτηση περισσότερων σχετικών εγγράφων σε μεγαλύτερες λίστες αποτελεσμάτων.

Οι τιμές οι τιμές Precision@5, Precision@10, Precision@15 και Precision@20 παραμένουν σταθερές, καθώς τα πρώτα 20 αποτελέσματα είναι ίδια ανεξαρτήτως της τιμής του k.

6. Σύγκριση με τα Αποτελέσματα της Φάσης 1

Συγκρίνοντας τα αποτελέσματα της Φάσης 2 με τα αντίστοιχα της Φάσης 1, παρατηρούμε ότι το BM25Similarity υπερέχει σε όλα τις μετρικές, τόσο ως προς το MAP όσο και ως προς την Precision@k. Συγκεκριμένα, για k=20 το MAP του BM25 είναι 0.6895, ενώ για τη σημασιολογική προσέγγιση είναι 0.3129. Αντίστοιχη διαφορά παρατηρείται και για μεγαλύτερες τιμές του k. Τα αποτελέσματα δείχνουν ότι, για το συγκεκριμένο σύνολο δεδομένων, η λεξική ανάκτηση παραμένει ιδιαίτερα αποτελεσματική, ενώ η σημασιολογική προσέγγιση παρουσιάζει σταθερή αλλά χαμηλότερη απόδοση.

Τα χαμηλότερα αποτελέσματα της Φάσης 2 σε σύγκριση με τη Φάση 1 δικαιολογούνται από τη φύση της συλλογής IR2025. Η συλλογή (dataset από EU-funded projects, κυρίως Horizon 2020, με abstracts στα αγγλικά) αποτελείται από **περιλήψεις** από τεχνικά και επιστημονικά κείμενα, όπου η ακριβής ταύτιση όρων παίζει καθοριστικό ρόλο στη συνάφεια. Σε τέτοια σύνολα δεδομένων η ακριβής ταύτιση όρων παίζει καθοριστικό ρόλο στη συνάφεια, γεγονός που ευνοεί ιδιαίτερα τη λεξική ανάκτηση με BM25.

Αντίθετα, η σημασιολογική ανάκτηση βασίζεται στη γενική εννοιολογική ομοιότητα των κειμένων και μπορεί να ανακτήσει έγγραφα που είναι σημασιολογικά κοντά αλλά δεν περιέχουν τους ίδιους όρους με το ερώτημα, και συνεπώς δεν θεωρούνται σχετικά στα qrels. (βλέπε: Thakur et al. (2021))

7. Πηγές

I. https://github.com/facebookresearch/faiss

II. https://github.com/facebookresearch/faiss/wiki/Faiss-indexes

III. Thakur, N., Reimers, N., Ranade, A., Bhatt, A., & Gurevych, I. (2021). BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models. In Thirty-Fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track (Round 2). (https://arxiv.org/abs/2104.08663)