ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2025 – 2026
ΜΑΘΗΜΑ: Συστήματα Ανάκτησης Πληροφοριών
Προγραμματιστική εργασία: Σημασιολογική ανάκτηση

Φάση 3 – Υβριδικό σύστημα ανάκτησης: συνδυασμός κλασικής και σημασιολογικής ανάκτησης

Περιγραφή

Στη Φάση 3 υλοποιήθηκε ένα υβριδικό σύστημα ανάκτησης πληροφορίας, το οποίο συνδυάζει την κλασική ανάκτηση με τη σημασιολογική αναζήτηση. Η βασική ιδέα είναι η αρχική ανάκτηση ενός περιορισμένου συνόλου υποψήφιων εγγράφων με τη χρήση του μοντέλου BM25Similarity και η επαναταξινόμησή τους μέσω σημασιολογικής ομοιότητας, αξιοποιώντας embeddings από transformer και τον μηχανισμό FAISS.

Η προσέγγιση αυτή στοχεύει στη μείωση του χώρου αναζήτησης για τη σημασιολογική ανάκτηση, διατηρώντας παράλληλα την ακρίβεια της αρχικής λεξικής αναζήτησης.

Ροή δεδομένων και υλοποίηση

Για κάθε ερώτημα της συλλογής IR2025 ακολουθήθηκαν τα παρακάτω βήματα:

1. **Αρχική ανάκτηση (Candidate Retrieval)**

   Το ερώτημα εκτελείται στο ευρετήριο ElasticSearch που δημιουργήθηκε στη Φάση 1, χρησιμοποιώντας το μοντέλο BM25Similarity. Από το ευρετήριο ανακτώνται τα N πιο σχετικά έγγραφα (στην παρούσα υλοποίηση N = 200).

   Στη Φάση 3 δεν φορτώνεται εκ νέου η αρχική συλλογή documents.csv, καθώς τα κείμενα των εγγράφων ανακτώνται απευθείας από το ευρετήριο ElasticSearch που δημιουργήθηκε στην Φάση 1 και το έχουμε ονομάσει ir2025_index. Άρα Αν δεν υπάρχει το index, τότε θα πρέπει να τρέξουμε από την Φάση 1 (phase 1.ipynb) εκείνα τα τα cells που δημιουργούν το index και κάνουν bulk indexing από documents.csv.

   Άρα για να δουλέψει η Φάση3, ο ElasticSearch server πρέπει να είναι ανοιχτός, δηλαδή να τρέξουμε το elasticsearch.bat (στα Windows), όπως στην Φάση 1.

2. **Δημιουργία ενθέσεων (Embeddings)**

   Για τα N υποψήφια έγγραφα, καθώς και για το ίδιο το ερώτημα, υπολογίζονται embeddings με το ίδιο προεκπαιδευμένο μοντέλο transformer που χρησιμοποιήθηκε στη Φάση 2 (all-MiniLM-L6-v2).

   Τα embeddings κανονικοποιούνται (normalize_embeddings=True), ώστε η σύγκριση να βασίζεται στη συνημιτονοειδή ομοιότητα (cosine similarity).

3. **Δυναμικό FAISS index και επαναταξινόμηση**

   Για κάθε ερώτημα δημιουργείται δυναμικά ένα FAISS index (με την βοήθεια της συνάρτησης `faiss_rerank()`), στο οποίο προστίθενται τα embeddings των N υποψήφιων εγγράφων. Η

αναζήτηση στο FAISS πραγματοποιείται με inner product, το οποίο σε κανονικοποιημένα embeddings ισοδυναμεί με cosine similarity.

Από το FAISS επιστρέφονται τα k πιο κοντινά έγγραφα (k = 20, 30, 50), τα οποία αποτελούν την τελική κατάταξη.

Στη Φάση 3 τα embeddings των εγγράφων δεν αποθηκεύονται μόνιμα, καθώς το FAISS χρησιμοποιείται αποκλειστικά για re-ranking ενός μικρού συνόλου υποψήφιων εγγράφων που διαφέρει ανά ερώτημα. Για τον λόγο αυτό, το FAISS index δημιουργείται δυναμικά ανά query και αποδεσμεύεται μετά την ολοκλήρωση της αναζήτησης, δεν αποθηκεύεται μόνιμα στο δίσκο όπως στην Φάση 2

Παραγωγή αρχείων αποτελεσμάτων

Για κάθε τιμή του k (20, 30, 50) δημιουργούνται αρχεία αποτελεσμάτων σε μορφή συμβατή με το εργαλείο αξιολόγησης trec_eval. Τα αρχεία αυτά περιέχουν, για κάθε ερώτημα, την τελική κατάταξη των εγγράφων με βάση τη βαθμολογία που προκύπτει από το FAISS. Τα αρχεία που προκύπτουν είναι **phase3_faiss_k20.txt**, **phase3_faiss_k30.txt**, **phase3_faiss_k50.txt**, μέσα στον φάκελο runs_phase3.

Στην συνέχεια, όπως και στις προηγούμενες Φάσεις, έχοντας τα προηγούμενα τρία αρχεία και το αρχείο με τις σωστές απαντήσεις (qrels.txt) στον ίδιο φάκελο με το trec_eval.exe, εκτελούμε, σε περιβάλλον cmd, τις εντολές:

```
trec_eval.exe qrels.txt phase3_faiss_k20.txt  > phase3_faiss_results_k20.txt
trec_eval.exe qrels.txt phase3_faiss_k30.txt  > phase3_faiss_results_k30.txt
trec_eval.exe qrels.txt phase3_faiss_k50.txt  > phase3_faiss_results_k50.txt
```

οι οποίες στέλνουν τα αποτελέσματα των εκτελέσεων στα αρχεία **phase3_faiss_results_k20.txt**, **phase3_faiss_results_k30.txt** και **phase3_faiss_results_k50.txt**, για να τις έχουμε διαθέσιμες για περαιτέρω επεξεργασία. Από τα αποτελέσματα αυτών των αρχείων, όπως και στις προηγούμενες Φάσεις παίρνουμε:

k	MAP	Precision@5	Precision@10	Precision@15	Precision@20
20	0.3634	0.6800	0.5500	0.4400	0.4000
30	0.4250	0.6800	0.5500	0.4400	0.4000
50	0.4708	0.6800	0.5500	0.4400	0.4000

Σύγκριση αποτελεσμάτων των Φάσεων

Συγκρίνοντας συνολικά τις τρεις φάσεις, παρατηρείται ότι η κλασική λεξική ανάκτηση της Φάσης 1 παρουσιάζει την καλύτερη απόδοση, ιδιαίτερα στα πρώτα αποτελέσματα της κατάταξης, όπως αποτυπώνεται στις υψηλές τιμές Precision@k και MAP. Αυτό δείχνει ότι για τη συγκεκριμένη συλλογή εγγράφων και τα αντίστοιχα ερωτήματα, η ακριβής αντιστοίχιση όρων παραμένει ιδιαίτερα αποτελεσματική.

Η Φάση 2, η οποία βασίζεται αποκλειστικά σε σημασιολογική ανάκτηση μέσω transformer embeddings και FAISS, εμφανίζει αισθητά χαμηλότερες επιδόσεις. Παρότι εντοπίζει σχετικά έγγραφα, δυσκολεύεται να τα κατατάξει στις πρώτες θέσεις, γεγονός που είναι αναμενόμενο

δεδομένου ότι χρησιμοποιείται προεκπαιδευμένο μοντέλο γενικού σκοπού χωρίς προσαρμογή στη συγκεκριμένη συλλογή.

Η Φάση 3 επιχειρεί να συνδυάσει τα πλεονεκτήματα των δύο προηγούμενων προσεγγίσεων μέσω υβριδικής ανάκτησης και σημασιολογικής επαναταξινόμησης. Τα αποτελέσματα δείχνουν σαφή βελτίωση σε σχέση με τη Φάση 2, ιδιαίτερα ως προς το MAP, γεγονός που υποδηλώνει ότι η σημασιολογική πληροφορία συνεισφέρει στη συνολική ανάκτηση σχετικών εγγράφων. Ωστόσο, η Φάση 3 δεν καταφέρνει να υπερβεί τη Φάση 1 ως προς την ακρίβεια στα πρώτα αποτελέσματα, επιβεβαιώνοντας ότι στη συγκεκριμένη περίπτωση η σημασιολογική προσέγγιση λειτουργεί κυρίως συμπληρωματικά και όχι ως αντικατάσταση της λεξικής ανάκτησης.

Συνδυασμός βαθμολογιών (Fusion)

Σταθμισμένος μέσος όρος BM25 score και cosine similarity

Εκτός από την κατάταξη που προκύπτει αποκλειστικά από το FAISS, υλοποιήσαμε και έναν μηχανισμό (συνάρτηση `fusion_rerank()`) συνδυασμού βαθμολογιών (fusion). Στην περίπτωση αυτή, η τελική βαθμολογία κάθε εγγράφου υπολογίζεται ως σταθμισμένος μέσος όρος της βαθμολογίας του BM25Similarity και της σημασιολογικής ομοιότητας (cosine similarity), μετά από κανονικοποίηση των επιμέρους βαθμολογιών με min–max normalization, ώστε οι τιμές της BM25 βαθμολογίας και της συνημιτονοειδούς ομοιότητας να βρίσκονται στην ίδια κλίμακα.

Ο συνδυασμός των βαθμολογιών πραγματοποιήθηκε με σταθμισμένο μέσο όρο της λεξικής βαθμολογίας BM25 και της σημασιολογικής ομοιότητας (cosine similarity), σύμφωνα με τον παρακάτω τύπο:

```
final = alpha * bm25_n + (1.0 - alpha) * cos_n
```

Ο συντελεστής alpha ελέγχει τη σχετική συνεισφορά των δύο μετρικών, επιτρέποντας την ενίσχυση είτε της λεξικής (bm25_n) είτε της σημασιολογικής (cos_n) πληροφορίας.

Επιλέξαμε alpha = 0.7, ώστε να δώσουμε μεγαλύτερο βάρος στο BM25, το οποίο αποδείχθηκε πιο ισχυρό στις προηγούμενες φάσεις, ενώ ταυτόχρονα να διατηρήσουμε μια ουσιαστική συμβολή της σημασιολογικής ομοιότητας.

Όπως και προηγουμένως, για κάθε τιμή του k (20, 30, 50) δημιουργούνται αρχεία αποτελεσμάτων σε μορφή συμβατή με το εργαλείο αξιολόγησης trec_eval. Τα αρχεία αυτά περιέχουν, για κάθε ερώτημα, την τελική κατάταξη των εγγράφων με βάση τη βαθμολογία που προκύπτει από τον συνδυασμό βαθμολογιων. Τα αρχεία που προκύπτουν είναι **phase3_fusion_k20.txt**, **phase3_fusion_k30.txt**, **phase3_fusion_k50.txt**, μέσα στον φάκελο runs_phase3.

Στην συνέχεια, όπως και στις προηγούμενες Φάσεις, έχοντας τα προηγούμενα τρία αρχεία και το αρχείο με τις σωστές απαντήσεις (qrels.txt) στον ίδιο φάκελο με το trec_eval.exe, εκτελούμε, σε περιβάλλον cmd, τις εντολές:

```
trec_eval.exe qrels.txt phase3_fusion_k20.txt  > phase3_fusion_results_k20.txt
trec_eval.exe qrels.txt phase3_fusion_k30.txt  > phase3_fusion_results_k30.txt
trec_eval.exe qrels.txt phase3_fusion_k50.txt  > phase3_fusion_results_k50.txt
```

οι οποίες στέλνουν τα αποτελέσματα των εκτελέσεων στα αρχεία **phase3_fusion_results_k20.txt**, **phase3_fusion_results_k30.txt** και **phase3_fusion_results_k50.txt**, για να τις έχουμε διαθέσιμες για περαιτέρω επεξεργασία. Από τα αποτελέσματα αυτών των αρχείων παίρνουμε:

k	MAP	Precision@5	Precision@10	Precision@15	Precision@20
20	0.6698	0.9000	0.7800	0.6800	0.5950
30	0.7411	0.9000	0.7800	0.6800	0.5950
50	0.7660	0.9000	0.7800	0.6800	0.5950

Από τα αποτελέσματα αυτά, μπορούμε να συμπεράνουμε ότι η προσέγγιση με συνδυασμό βαθμολογιών (fusion) παρουσιάζει σαφή βελτίωση σε σχέση με τη Φάση 2 και τα αποτελέσματα της καθαρής σημασιολογικής επαναταξινόμησης. Σε σύγκριση με τη Φάση 1, παρατηρείται βελτίωση στα Precision@5 και Precision@10, ενώ το MAP παραμένει σε παρόμοια επίπεδα. Τα αποτελέσματα αυτά δείχνουν ότι ο συνδυασμός της λεξικής βαθμολογίας BM25 με τη σημασιολογική ομοιότητα επιτρέπει τη βελτίωση της ποιότητας των πρώτων αποτελεσμάτων (κορυφή της κατάταξης), χωρίς να υποβαθμίζεται η συνολική απόδοση του συστήματος.

Πηγές

I. https://github.com/facebookresearch/faiss
II. https://github.com/facebookresearch/faiss/wiki/Faiss-indexes
III. Hybrid Search Explained: https://weaviate.io/blog/hybrid-search-explained
IV. What is hybrid search? https://www.elastic.co/what-is/hybrid-search