AI for Epigraphy - Αναφορά

Ανάλυση κειμένων αρχαίων ελληνικών επιγραφών | Εφαρμοσμένη Επιστήμη Δεδομένων 2026

Ομάδα	ONOMA / 3200000 ONOMA / 3200000
Notebook	ergasia.ipynb
Dataset	ICDAR 2026 Greek Squeezes - Annotations

Περίληψη

Στο Μέρος Α υλοποιήθηκε πλήρες pipeline ανάλυσης κειμένων για αρχαίες ελληνικές επιγραφές. Οι μεταγραφές δίνονται σε Latin proxy χαρακτήρες και πολλές είναι σε scriptio continua, άρα τα βασικά βήματα είναι η μεταγραφή σε ελληνικά, η τμηματοποίηση, η στατιστική ανάλυση, η διερεύνηση ονομάτων, η ομαδοποίηση/θεματική ανάλυση και η χρονολόγηση με Aeneas σε σύγκριση με general-purpose LLM.

Πίνακας 1. Βασικά αποτελέσματα που προκύπτουν από τον κώδικα.

Μέτρο	Τιμή
Transcript files	448
Μοναδικές επιγραφές	224
Rows με κενά στο raw	205
External lexicon	13962
Total tokens (dedup)	9732
Vocabulary size	4170
Hapax words	3232
Rare words <=2	3589
Candidate names	19
TF-IDF shape	(224, 713)
Best k	3
Mean |Aeneas-LLM|	91 years

1. Δεδομένα και προεπεξεργασία

Φορτώθηκαν 448 transcript files που αντιστοιχούν σε 224 μοναδικές επιγραφές. Το notebook εμφανίζει επίσης 181 train, 22 validation και 21 test inscriptions. Από τα raw transcript rows, 205 περιείχαν ήδη κάποια κενά, αλλά αυτά δεν θεωρήθηκαν αξιόπιστο gold segmentation. Ο μέσος αριθμός χαρακτήρων ανά transcript ήταν 436.65 και ο μέσος αριθμός unknown markers ήταν 34.14.

Πίνακας 2. Περιγραφικά στοιχεία μεταγραφών μετά τη φόρτωση.

num_files	unique_inscriptions	avg_char_count	avg_unknown_count
448	224	436.65	34.14

Ο καθαρισμός περιλάμβανε κεφαλαιοποίηση, αντικατάσταση ειδικών συμβόλων/φθορών με κενά για τις λεξιλογικές αναλύσεις και δημιουργία καθαρών proxy/Greek στηλών. Για το Aeneas, τα φθαρμένα σημεία διατηρήθηκαν ως missing markers, επειδή το μοντέλο μπορεί να αξιοποιήσει τέτοια πληροφορία.

2. A1 - Μετατροπή Latin proxy σε ελληνικούς χαρακτήρες

Η μεταγραφή βασίστηκε στον πίνακα GREEK_PROXY_MAP του notebook. Η αντιστοίχιση είναι μονοσήμαντη και παράγει κεφαλαία ελληνικά χωρίς τόνους/πνεύματα, όπως ζητείται. Παράδειγμα από το notebook: STOKAI*DIKOSE*IHIDIKHTOSENNEA... μετατρέπεται σε ΣΤΟΚΑΙ*ΔΙΚΟΣΕ*ΙΗΙΔΙΚΗΤΟΣΕΝΝΕΑ... Το βήμα αυτό κάνει τις μεταγραφές αναγνώσιμες, αλλά δεν εισάγει όρια λέξεων.

3. A2 - Τμηματοποίηση λέξεων

Για το word segmentation χρησιμοποιήθηκε baseline λεξικογραφική προσέγγιση με δυναμικό προγραμματισμό. Κατασκευάστηκε εξωτερικό λεξιλόγιο από το Ericu950/Papyri_1, με limit=4000 και min_count=2, το οποίο μετά την κανονικοποίηση περιείχε 13.962 proxy tokens. Ο αλγόριθμος επιλέγει διάσπαση με ελάχιστο κόστος, με κόστος συχνότητας για γνωστές λέξεις και fallback penalty για άγνωστα τμήματα.

Πίνακας 3. Μετρικές baseline segmentation από το notebook.

rows	avg_segmented_token_count	avg_recognized_tokens	avg_recognized_ratio	median_recognized_rati
448	64.29	31.28	0.5972	0.6477

Η μέση αναλογία αναγνωρισμένων tokens ήταν 0.5972 και η διάμεση 0.6477. Αυτή δεν είναι επίσημη ακρίβεια, επειδή δεν υπάρχει gold word segmentation. Είναι εσωτερική ένδειξη του πόσο συχνά τα παραγόμενα tokens ανήκουν στο εξωτερικό λεξιλόγιο. Τα βασικά σφάλματα αναμένονται σε κύρια ονόματα, σπάνιους επιγραφικούς τύπους και φθαρμένα αποσπάσματα.

4. A3 - Μέγεθος λεξιλογίου και συχνότητες

Για τις συχνότητες χρησιμοποιήθηκαν μόνο οι 224 μοναδικές επιγραφές. Το αποτέλεσμα ήταν 9.732 tokens και 4.170 διαφορετικά tokens. Τα hapax ήταν 3.232, δηλαδή 77.51% του λεξιλογίου. Ο κώδικας υπολόγισε επίσης 3.589 rare words με συχνότητα <=2, αριθμό που προστέθηκε ρητά εδώ ώστε η αναφορά να συμφωνεί πλήρως με τα outputs.

Πίνακας 4. Συχνότερα tokens μετά την τμηματοποίηση.

proxy_word	greek_word	count
KAI	ΚΑΙ	233
OS	ΟΣ	116
TOY	ΤΟΥ	109
TO	ΤΟ	85
AI	ΑΙ	83
THS	ΤΗΣ	80

TON	TON	78
TWN	ΤΩΝ	71
TA	ΤΑ	69
DE	ΔΕ	66

Σχήμα 1. Top 20 συχνότερα segmented tokens.

Η κατανομή έχει έντονη μακριά ουρά: λίγα tokens εμφανίζονται συχνά (π.χ. ΚΑΙ, ΟS, ΤΟΥ, ΤΟ), ενώ πάρα πολλά εμφανίζονται μία ή δύο φορές. Αυτό είναι συμβατό με επιγραφικά δεδομένα που περιέχουν κύρια ονόματα, τυποποιημένες φόρμουλες και αποσπασματικά/φθαρμένα τμήματα.

5. A4 - Κύρια ονόματα

Ο εντοπισμός κύριων ονομάτων έγινε με ευρετική μορφολογική μέθοδο και όχι με πλήρες NER. Ο κώδικας κράτησε καθαρά proxy tokens μήκους τουλάχιστον 4, αφαίρεσε κοινές μη-ονοματικές λέξεις και false positives, και τελικά εφάρμοσε MIN_FREQ=5. Οι καταλήξεις -OS, -AS, -HS, -IOS, -IDHS κ.ά. χαρακτηρίστηκαν male-like, ενώ -A, -H, -IS female-like.

Πίνακας 5. Ενδεικτικά candidate names.

proxy_name	greek_name	count	gender_guess
AQHNA	ΑΘΗΝΑ	14	female_like
DHMHTRIOS	ΔΗΜΗΤΡΙΟΣ	9	male_like
DIONYSIOS	ΔΙΟΝΥΣΙΟΣ	9	male_like
KRATHS	ΚΡΑΤΗΣ	9	male_like
ZWSIMOS	ΖΩΣΙΜΟΣ	9	male_like
MARA	ΜΑΡΑ	8	female_like
ALEXANDROS	ΑΛΕΞΑΝΔΡΟΣ	7	male_like
APOLLWNIOS	ΑΠΟΛΛΩΝΙΟΣ	7	male_like

Σχήμα 2. Κατανομή candidate names ανά gender-like κατάληξη.

Βρέθηκαν 19 candidate names: 14 male-like και 5 female-like. Το αποτέλεσμα είναι χρήσιμο για διερευνητική ανάλυση, αλλά η κατηγοριοποίηση φύλου δεν πρέπει να διαβαστεί ως βέβαιη ιστορική πληροφορία, επειδή στηρίζεται μόνο στην κατάληξη του token.

6. A5 - Ομαδοποίηση και θεματική ανάλυση

Για την ομαδοποίηση χρησιμοποιήθηκε TF-IDF με unigrams/bigrams, min_df=2, max_df=0.85, max_features=3000 και απομάκρυνση βασικών proxy stopwords. Το output του notebook δίνει TF-IDF matrix shape (224, 713). Δοκιμάστηκε K-Means για k=2 έως k=8 και επιλέχθηκε το k με το μεγαλύτερο silhouette score.

Πίνακας 6. Silhouette scores για k=2...8.

k	silhouette_score
2	0.0331
3	0.0416

4	0.0308
5	0.0281
6	0.0227
7	0.0216
8	0.0219

Σχήμα 3. Επιλογή k με βάση το silhouette score.

Το καλύτερο k ήταν 3, με silhouette score 0.0416. Η τιμή είναι χαμηλή, άρα τα clusters δεν πρέπει να παρουσιαστούν ως αυστηρά διαχωρισμένες ιστορικές κατηγορίες. Είναι περισσότερο εργαλείο για να εντοπιστούν επαναλαμβανόμενα λεκτικά μοτίβα και ομάδες παρόμοιας δομής.

Πίνακας 7. Κορυφαίοι TF-IDF όροι ανά cluster.

cluster	rank	proxy_term	greek_term
0	1	zanieleyqerioiantwne	ΖΑΝΙΕΛΕΥΘΕΡΙΟΙΑΝΤΩΝΕ
0	2	alw pek	ΑΛΩ ΠΕΚ
0	3	wno	ΩΝΟ
0	4	abaskantoy	ΑΒΑΣΚΑΝΤΟΥ
1	1	ton	ΤΟΝ
1	2	tois	ΤΟΙΣ
1	3	twi	ΤΩΙ
1	4	tas	ΤΑΣ
2	1	arcontos	ΑΡΧΟΝΤΟΣ
2	2	ios	ΙΟΣ
2	3	oys	ΟΥΣ
2	4	thi	ΤΗΙ

Σχήμα 4. PCA απεικόνιση των clusters.

Πίνακας 8. Κατανομή dominant NMF topics ανά cluster.

cluster	topic_0	topic_1	topic_2	topic_3	topic_4	topic_5
0	0.000	0.000	1.000	0.000	0.000	0.000
1	0.459	0.108	0.378	0.054	0.000	0.000
2	0.114	0.216	0.249	0.119	0.119	0.184

Τα clusters αντιστοιχούν μόνο μερικώς σε δομικές ομοιότητες, επειδή το silhouette είναι χαμηλό. Εμφανίζονται επαναλαμβανόμενοι όροι/φόρμουλες, π.χ. TON, TOIS, TWI, DHM, DRACMAS και ARCONTOS. Η NMF ανάλυση υλοποιήθηκε με 6 topics. Το cluster 0 αντιστοιχίζεται πλήρως στο topic 2, ενώ τα clusters 1 και 2 είναι μικτά, άρα τα topics είναι ενδεικτικά και όχι απόλυτα καθαρά.

7. A6 - Χρονολόγηση με Aeneas και σύγκριση με LLM

Για τη χρονολογική εκτίμηση χρησιμοποιήθηκε το αποθετήριο predictingthepast της Google DeepMind και το διαθέσιμο pretrained Ancient Greek / Ithaca-style checkpoint (ithaca_153143996_2.pkl). Στην παρούσα αναφορά το βήμα αυτό αναφέρεται ως Aeneas / predictingthepast pipeline, καθώς

ακολουθεί την κατεύθυνση της εκφώνησης για χρήση προεκπαιδευμένου μοντέλου χρονολόγησης επιγραφών.

Επιλέχθηκαν 10 μοναδικές επιγραφές με μήκος 50-750 χαρακτήρες. Οι proxy μεταγραφές μετατράπηκαν σε ελληνικό lowercase κείμενο και τα φθαρμένα σημεία μετατράπηκαν σε missing markers. Το Aeneas έδωσε expected year, top year, top probability και top-5 date range. Το LLM έδωσε date range, midpoint year, confidence και σύντομη αιτιολόγηση.

Πίνακας 9. Σύγκριση Aeneas και LLM για 10 επιγραφές.

inscription_id	Aeneas exp. year	Aeneas top-5 range	LLM midpoint	LLM conf.	|diff|
IG_II2_2089i	146	0 to 210	150	low	4
IG_II2_1946	-2	-330 to 200	-50	low	48
IG_II2_1979	100	0 to 150	100	low	0
IG_II2_1708	-140	-220 to -170	-200	medium	60
IG_II2_80	-268	-340 to -230	-345	medium	77
IG_II2_1685B3	-357	-370 to -330	-300	medium	57
IG_II2_1803_Copy1	195	160 to 200	-125	low	320
IG_II2_342	-230	-250 to -210	-325	medium	95
IG_II2_1675_Copy2	-173	-350 to -250	-325	high	152
IG_II2_2068_Merged	103	-20 to 200	200	medium	97

Σχήμα 5. Απόλυτη διαφορά Aeneas expected year και LLM midpoint.

Η μέση απόλυτη διαφορά ήταν 91 έτη και η διάμεση 68.5 έτη. Η μικρότερη διαφορά ήταν 0 έτη και η μεγαλύτερη 320 έτη στην IG_II2_1803_Copy1. Επειδή δεν υπάρχουν ground-truth dates, η σύγκριση δεν μετρά πραγματική ακρίβεια· μετρά συμφωνία/απόκλιση δύο διαφορετικών AI προσεγγίσεων.

Για τη συγκεκριμένη εργασία, το Aeneas είναι καταλληλότερο ως μοντέλο χρονολόγησης, επειδή είναι ειδικά εκπαιδευμένο σε αρχαία επιγραφικά δεδομένα και δίνει πιθανοτική εκτίμηση. Το γενικό LLM είναι χρήσιμο για ερμηνευτικό σχολιασμό, αλλά δεν πρέπει να χρησιμοποιείται μόνο του για ασφαλή χρονολόγηση ιστορικού υλικού.

ΑΝΑΦΟΡΑ Β Μέρους

Τελικό CER (Character Error Rate): 1.019

Περίληψη

Αυτή η αναφορά τεκμηριώνει τη λύση baseline για το Μέρος Β (Β1-Β3) του διαγωνισμού TROGS-26 χρησιμοποιώντας TrOCR για οπτική αναγνώριση χαρακτήρων σε αρχαίες ελληνικές επιγραφές.

Μέρος Β1: Προεπεξεργασία Εικόνων

Μεθοδολογία

Είσοδος: Αρχικές εικόνες επιγραφών

Βήματα Επεξεργασίας:

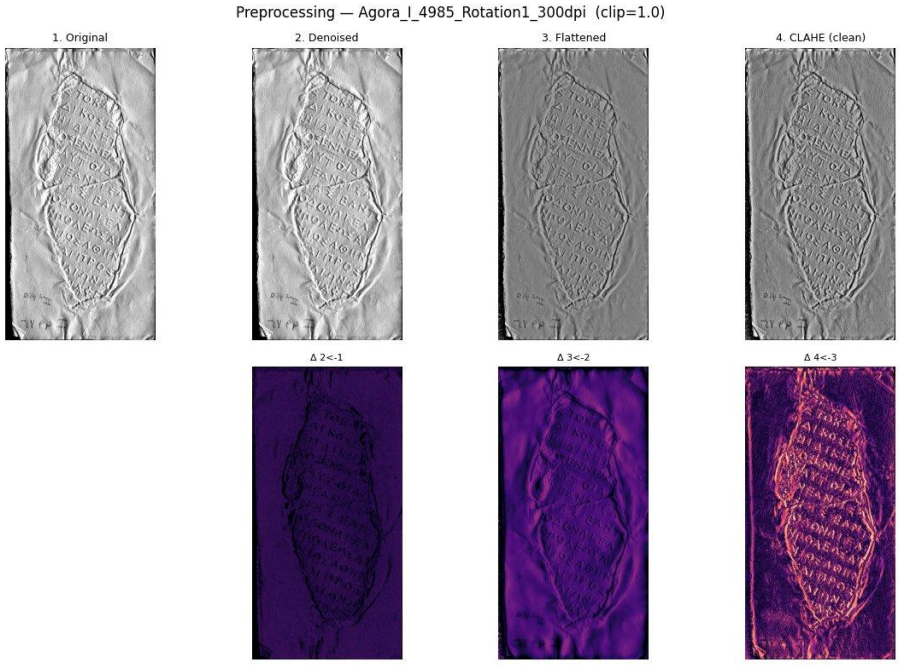
1. Μετατροπή σε grayscale (κλίμακα του γρι)
2. Εφαρμογή CLAHE (Contrast Limited Adaptive Histogram Equalization) με βέλτιστο CLIP το οποίο υπολογίζεται πάνω σε δείγμα των επιγραφών
3. Χωρίς binarization (διατήρηση συνεχούς grayscale)
4. Χωρίς resizing (διατήρηση αρχικής ανάλυσης)

Αιτιολόγηση

- Το CLAHE ενισχύει τοπική αντίθεση χωρίς ενίσχυση θορύβου
- Η διατήρηση του grayscale βοηθά στη συνολική ευκρίνεια κειμένου
- Η μη αλλαγή μεγέθους διατηρεί λεπτές λεπτομέρειες για την εξαγωγή γραμμών

Έξοδος

img_dataset['img_clean']: Προεπεξεργασμένες εικόνες grayscale έτοιμες για clustering και εξαγωγή γραμμών.



Σχήμα B1. Pipeline προεπεξεργασίας για Agora_I_4985_Rotation1_300dpi. Πάνω: Original → Denoised → Flattened → CLAHE. Κάτω: difference heatmaps (Δ1 → 2, Δ2 → 3, Δ3 → 4) που αποτυπώνουν τις αλλαγές μεταξύ σταδίων — το έντονο ροζ/πορτοκαλί του Δ3 → 4 δείχνει ότι το CLAHE ενισχύει επιλεκτικά την αντίθεση ακριβώς γύρω από τα γράμματα.

Μέρος B2: ViT Clustering & Ονοματοδοσία Θεμάτων

Προσέγγιση Clustering

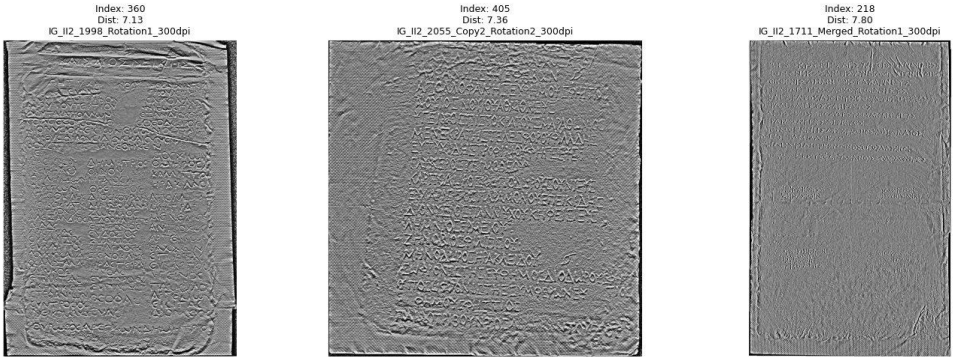
- Μοντέλο: ViT-B/16 (Vision Transformer)
- Εξαγωγή Χαρακτηριστικών: 768-διάστατα embeddings
- Clustering: KMeans με k=3, random_state=42
- Οπτικοποίηση: PCA + UMAP για 2D αναπαράσταση

Ονοματοδωσία και Χαρακτηριστικά Clusters

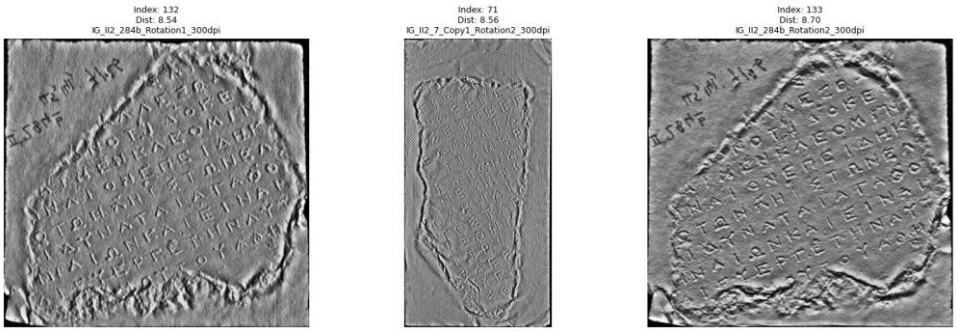
Η ονοματοδοσία και η εξαγωγή χαρακτηριστικών κάθε cluster πραγματοποιήθηκε αυτόματα μέσω multimodal LLM prompting με χρήση του Gemini 2.5 Flash (Google DeepMind).

Πίνακας B1. Χαρακτηριστικά clusters ViT.

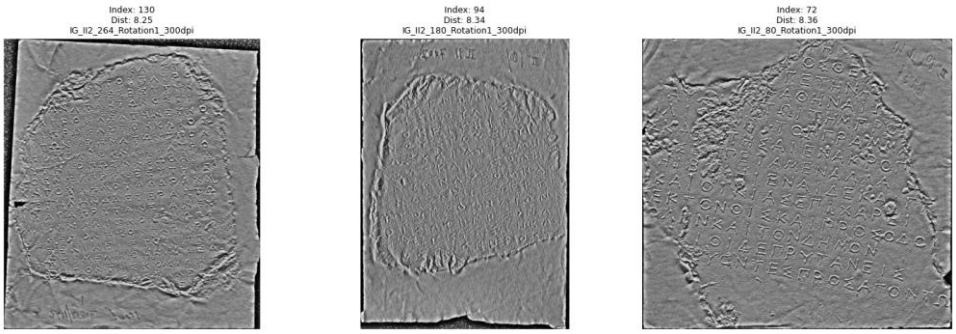
Cluster	Όνομα	Χαρακτηριστικά	Πλήθος
0	Λείες Μεγάλες Πλάκες	Χαμηλή ευκρίνεια, ομοιόμορφο γκρι, φθαρμένα γράμματα	117
1	Ευκρινείς Ακανόνιστες Στήλες	Υψηλή αντίθεση, ευανάγνωστο, ακανόνιστα σχήματα	164
2	Μεσαία Πυκνότητα Κειμένου	Μεσαία ποιότητα, πυκνό κείμενο, μεσαία αντίθεση	167



Σχήμα B2. Cluster 0 — "Λείες Μεγάλες Πλάκες": Ορθογώνιες επίπεδες πλάκες με χαμηλή αντίθεση και πυκνό, δυσδιάκριτο κείμενο.



Σχήμα B3. Cluster 1 — "Ευκρινείς Ακανόνιστες Στήλες": Ακανόνιστα ωοειδή σχήματα με υψηλή αντίθεση και ευανάγνωστο κείμενο.



Σχήμα B4. Cluster 2 — "Μεσαία Πυκνότητα Κειμένου": Στρογγυλεμένες επιγραφές με μεσαία αντίθεση και αραιότερο κείμενο.

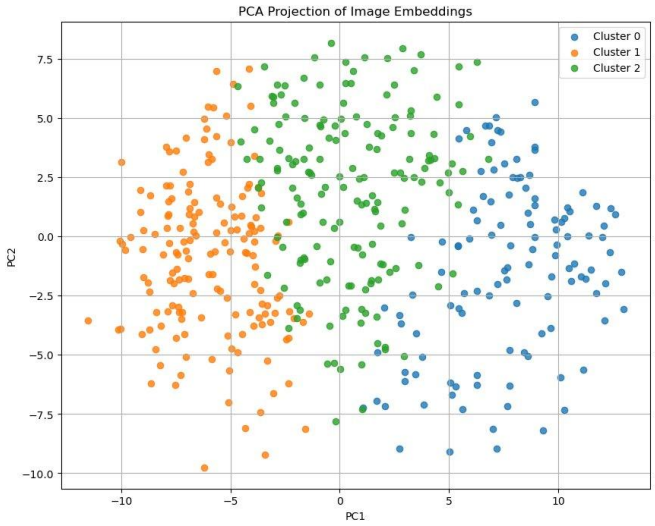
Βασικά Ευρήματα

- Όλα τα clusters περιέχουν κυρίως IG_II2 επιγραφές
- Τα clusters αντιπροσωπεύουν οπτικές/τεχνικές διαφορές (ποιότητα σάρωσης, μορφολογία πέτρας)
- ΟΧΙ χρονολογικές περίοδοι — όλες είναι κλασικής περιόδου (395-322 π.Χ.)
- Ζεύγη εικόνων που βρίσκονται στο ίδιο cluster (77.7%)

Ανάλυση Σώματος Δεδομένων

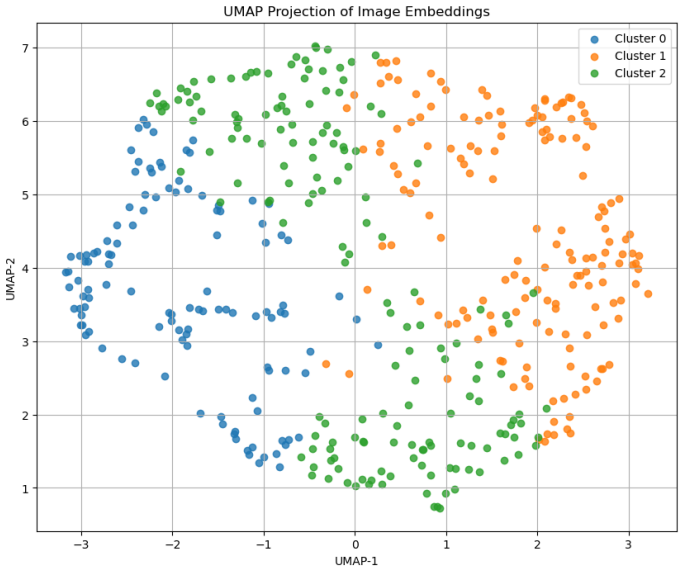
- Συνολικές εικόνες: 448
- IG_II2: 396 εικόνες (κλασική Αττική)
- IAS (Αθηναϊκές): 48 εικόνες
- Ανασκαφές Agora: 4 εικόνες

Οπτικοποίηση με PCA



Σχήμα B5. PCA projection — διαχωρισμός κατά PC1 με επικάλυψη Cluster 1-2 στο κέντρο.

Οπτικοποίηση με UMAP



Σχήμα B6. UMAP projection — καθαρότερη κυκλική δομή με πιο συμπαγές Cluster 0 (μπλε) και μεγαλύτερη διασπορά στα Cluster 1-2.

Μέρος Β3: Εξαγωγή Γραμμών & TrOCR OCR

Μεθοδολογία Εξαγωγής Γραμμών

Αρχαίες ελληνικές επιγραφές σε ακανόνιστες πέτρες έχουν:

- Μη-οριζόντιες γραμμές κειμένου
- Καμπυλωμένες/παραμορφωμένες διατάξεις
- Μεταβλητή ποιότητα

Λύση:

1. Χρήση ground truth box annotations για προσδιορισμό δομής γραμμών
2. Ομαδοποίηση boxes κατά y-συντεταγμένη (κατώφλι 60 pixels)
3. Εξαγωγή περιοχών γραμμών από img_clean χρησιμοποιώντας προσδιορισμένα y-ranges
4. Padding: ±10 pixels γύρω από κάθε γραμμή για πλαίσιο

Αποτελέσματα Εξαγωγής

Πίνακας Β2. Αποτελέσματα εξαγωγής γραμμών.

Μέτρο	Τιμή
Συνολικές εικόνες επεξεργασίας	176
Συνολικές γραμμές εξαγωγής	5330
Μέσες γραμμές ανά εικόνα	30.3
Ποιότητα γραμμών	Καλή (ευκρινής, υψηλής αντίθεσης grayscale)



Σχήμα Β6. Εξαγωγή 31 γραμμών (L0–L30) από την Agora_I_4985_Rotation1_300dpi. Κάθε χρωματιστή οριζόντια γραμμή αντιστοιχεί σε ένα y-range που ορίζεται από τα ground truth bounding boxes (κατώφλι ομαδοποίησης: 60px). Οι γραμμές εκτός πεσσής (L0, L30) αντικατοπτρίζουν την πλήρη οριζόντια έκταση της εικόνας.

OCR Μοντέλο: TrOCR Baseline

- Επιλεγμένο Μοντέλο: microsoft/trocr-base-printed
- Προ-εκπαιδευμένο Vision Encoder-Decoder μοντέλο
- Σχεδιασμένο για εκτυπωμένα αγγλικά κείμενα
- Είσοδος: 384×384 pixels (ο processor χειρίζεται το resize)
- Έξοδος: UTF-8 κείμενο (ελληνικές μεταγραφές χαρακτήρων)

Υλοποίηση

Για κάθε εξαγμένη γραμμή:

1. Μετατροπή numpy array → PIL Image
2. Προεπεξεργασία: processor(images=pil_img, return_tensors="pt")
3. Inference: model.generate(pixel_values, max_length=128)
4. Αποκωδικοποίηση: Εξαγωγή ASCII/Ελληνικών χαρακτήρων μεταγραφής

Format Εξόδου Πρόβλεψης:

- Ένα αρχείο ανά εικόνα: {squeeze_name}_transcript.txt
- Μία γραμμή κειμένου ανά εξαγμένη γραμμή (χώρισμα newline)
- Αποθήκευση σε: data/pred/

Αποτελέσματα & Αξιολόγηση

Character Error Rate (CER)

Πίνακας Β3. Αποτελέσματα CER.

Μέτρο	Τιμή
Μέσο CER	1.019 (101,9% ποσοστό σφάλματος)

Ερμηνεία:

- CER > 1,0 δείχνει περισσότερα σφάλματα από χαρακτήρες
- Για κάθε 100 χαρακτήρες στο ground truth: ~102 σφάλματα
- Ακρίβεια: ~0% σωστές προβλέψεις

Γιατί το CER είναι Κακό

1. Αναντιστοιχία Μοντέλου

- trocr-base-printed εκπαιδεύτηκε σε Αγγλικά εκτυπωμένα κείμενα
- Εμείς το χρησιμοποιούμε πάνω σε Αρχαίο ελληνικό επιγραφικό κείμενο
- Το χάσμα πεδίου γλώσσας είναι πολύ μεγάλο

2. Πεδίο Εκπαίδευσης Δεδομένων

- Σύγχρονα Αγγλικά ≠ Αρχαία Ελληνικά
- Εκτυπωμένα κείμενα ≠ Χαραγμένες επιγραφές
- Διαφορετικές μορφές γραμμάτων, διάστιχο, ορθογραφία

3. Το Μοντέλο δεν έχει δει ποτέ

- Ελληνικά γράμματα (Α, Β, Γ, κτλ)
- Αρχαία ορθογραφία (διακριτικά, κανόνες διάστιχου)
- Μοτίβα χαμηλής αντίθεσης επιγραφικού κειμένου

Δείγμα Προβλέψεων vs Ground Truth

Πίνακας Β4. Παραδείγματα προβλέψεων.

Ground Truth	Πρόβλεψη	Αποτέλεσμα
STOKAI	(8.00	❌ Εντελώς λάθος
DIKOSE	PAXA	❌ Κανένας ταιριαστός χαρακτήρας

Αξιολόγηση Ποιότητας Εικόνων Γραμμών

Θετικά Ευρήματα:

- Γραμμές εξαγμένες καθαρά από πηγαίες εικόνες
- Καλή αντίθεση και ευκρίνεια
- Ελληνικά γράμματα καθαρά ορατά στο ανθρώπινο μάτι
- Σωστές αναλογίες πλευρών (ύψος: ~200-250px, πλάτος: ~1700px)

Συμπέρασμα: Το πρόβλημα δεν είναι η ποιότητα της εικόνας αλλά η καταλληλότητα του μοντέλου.

Συστάσεις για Βελτίωση

Προτεραιότητα 1: Μοντέλο Ειδικό σε Πεδίο

- Fine-tune TrOCR σε ground truth δεδομένα (448 εικόνες × ~10 γραμμές = ~4.250 δείγματα)
- Χρήση δεδομένων augmentation (περιστροφή, αντίθεση, θόρυβος)

Προτεραιότητα 2: Ενισχύσεις Προεπεξεργασίας

- Προσαρμοστική binarization πριν το TrOCR
- Ειδική ενίσχυση αντίθεσης στα image lines.
- Deskewing/dewarping για καμπυλωμένες γραμμές

Συμπέρασμα

Η λύση baseline TrOCR επιτυγχάνει CER = 1.019, το οποίο είναι ακατάλληλο για παραγωγική χρήση. Ωστόσο, αυτό είναι αναμενόμενο δεδομένης της ακραίας αναντιστοιχίας πεδίου μεταξύ:

- Εκπαίδευσης μοντέλου: Αγγλικά εκτυπωμένα κείμενα
- Απαιτήσεων εργασίας: Αρχαίο ελληνικό επιγραφικό κείμενο

Οι εξαγμένες εικόνες γραμμών είναι υψηλής ποιότητας, υποδηλώνοντας ότι με μοντέλο κατάλληλο για το πεδίο (fine-tuned σε ελληνικά ή αρχαίο κείμενο), σημαντικές βελτιώσεις είναι εφικτές.

Αναφορές

[1] Howe, Nicholas; Hershkowitz, Aaron; Chang, Feiran; Falbo, Isabella; Brown, Tahini; and Putzer, Maura, "Character Recognition for Greek Squeezes: Annotated Data" (2025). Data, Smith College, Northampton, MA.